

# Matrizes e Vetores

Vicente G. Cancho  
garibay@icmc.usp.br

Um **vetor** é um arranjo unidimensional :  $\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_s \end{pmatrix}_{s \times 1}$

Uma **matriz** é um arranjo bidimensional :

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{np} \end{pmatrix}_{n \times p} = \{a_{ij}\}_{n \times p}$$

A **ordem** de uma matriz se refere ao número de linhas e colunas:

- a ordem  $\mathbf{v}$  é  $s$  por  $1$ ;
- a ordem  $\mathbf{A}$  é  $n$  por  $p$

O **posto** de  $\mathbf{A}$  é o número de linhas/colunas linearmente independentes

- o **posto coluna** de  $\mathbf{A}$  é o número de colunas linearmente independentes.
- o **posto linha** de  $\mathbf{A}$  é o número de linhas linearmente independentes.

Dizemos que  $\mathbf{A}$  é de posto completo se  $\text{rank}(A) = \min(n, p)$

- Se  $n < p$ , **posto completo** implica **posto linha** completa, ou seja  $\text{rank}(A) = n$
- Se  $n > p$ , **posto completo** implica **posto coluna** completa, ou seja  $\text{rank}(A) = p$ .

# Exemplo-1

A matriz  $\mathbf{A}$  não é posto completo

$$\mathbf{A} = \begin{pmatrix} 1 & 3 \\ 2 & 6 \\ 5 & 15 \end{pmatrix}$$

porque temos  $3\mathbf{a}_1 = \mathbf{a}_2$ , onde  $\mathbf{a}_j$  denota a  $j$ -ésima coluna de  $\mathbf{A}$ .  
Em contraste, a matriz  $\mathbf{A}$  é de posto completo

$$\mathbf{A} = \begin{pmatrix} 1 & 3 \\ 2 & 6 \\ 4 & 15 \end{pmatrix}$$

porque não podemos escrever  $\sum_{j=1}^2 c_j \mathbf{a}_j = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$  a menos que definamos  $c_j = 0 \ \forall j$

# Transposta de uma matriz

A transposta de um vetor transforma um vetor coluna em um vetor linha

$$\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_s \end{pmatrix}_{s \times 1} \iff \mathbf{v}^T = (v_1 \quad v_2 \quad \cdots \quad v_s)_{1 \times s}$$

A transposta de uma matriz troca linhas e colunas, como

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{pmatrix}_{n \times p} \iff \mathbf{A}^T = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1p} & a_{2p} & \cdots & a_{np} \end{pmatrix}_{p \times n}$$

## Exemplo-2

A transposta do vetor  $\mathbf{v} = \begin{pmatrix} 1 \\ 3 \\ 4 \\ 7 \end{pmatrix}$  é dado por  $\mathbf{v}^T = (1 \ 3 \ 4 \ 7)$ .

transposta da matriz  $\mathbf{A} = \begin{pmatrix} 1 & 3 \\ 2 & 6 \\ 4 & 15 \end{pmatrix}$  é dado por  $\mathbf{A}^T = \begin{pmatrix} 1 & 2 & 3 \\ 3 & 6 & 15 \end{pmatrix}$

# Transposta de uma matriz: Propriedades

Algumas propriedades úteis de transposição de matriz incluem:

- $(\mathbf{A}^\top)^\top = \mathbf{A}$ ;
- $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$  (onde  $\mathbf{A} + \mathbf{B}$  soma de matrizes);
- $(c\mathbf{A})^\top = c\mathbf{A}^\top$  (onde  $c\mathbf{A}$  é o produto de um escalar e uma matriz).
- $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$  (onde  $\mathbf{AB}$  é o produto de matrizes);
- $(\mathbf{A}^{-1})^\top = (\mathbf{A}^\top)^{-1}$  (onde  $\mathbf{A}^{-1}$  é a matriz inversa  $\mathbf{A}$ ).

# Traço de uma matriz

O traço de uma matriz  $\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{p1} & a_{p2} & \dots & a_{pp} \end{pmatrix}_{p \times p}$  é

$$tr(\mathbf{A}) = \sum_{j=1}^p a_{jj}$$

que é a soma dos elementos diagonais.



## Exemplo 3

O traço da matriz  $\mathbf{A} = \begin{pmatrix} 1 & 4 & 8 & 13 \\ 2 & 8 & 11 & 2 \\ 7 & 2 & 6 & 9 \\ 5 & 9 & 4 & 3 \end{pmatrix}$  é

$$tr(\mathbf{A}) = 1 + 8 + 6 + 3 = 18$$

# Traço de uma matriz: Propriedades

Algumas propriedades úteis de transposição de matriz incluem:

- $tr(\mathbf{A}) = tr(\mathbf{A}^\top)$ ;
- $tr(\mathbf{A} + \mathbf{B}) = tr(\mathbf{A}) + tr(\mathbf{B})$  ;
- $tr(b\mathbf{A}) = b tr(\mathbf{A})$
- $tr(\mathbf{AB}) = tr(\mathbf{BA})$  se ambos produtos são bem definidos;
- Se  $\mathbf{A}$  é uma matriz simétrica, então  $tr(\mathbf{A}_{p \times p}) = \sum_{j=1}^p \lambda_j$ , onde  $\lambda_j$  é o  $j$ -ésimo autovalor da matriz  $\mathbf{A}$ .

Uma matriz simétrica é quadrada e simétrica ao longo da diagonal principal:

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{p1} & a_{p2} & \dots & a_{pp} \end{pmatrix}_{p \times p}$$

com  $a_{ij} = a_{ji}$  para todo  $i \neq j$

Observe que  $\mathbf{A} = \mathbf{A}^T$  para todas as matrizes simétricas (por definição)

## Matriz simétrica: Exemplo-4

A matriz  $\mathbf{A} = \begin{pmatrix} 9 & 1 & 0 & 4 \\ 1 & 4 & 2 & 1 \\ 0 & 2 & 5 & 6 \\ 4 & 1 & 6 & 8 \end{pmatrix}$  é simétrica e é de ordem  $4 \times 4$ .  $\mathbf{A}$

matriz  $\mathbf{A} = \begin{pmatrix} 9 & 1 & 0 & 4 \\ 1 & 4 & 2 & 4 \\ 0 & 2 & 5 & 6 \\ 4 & 1 & 6 & 8 \end{pmatrix}$  não é simétrica e é de ordem  $4 \times 4$ .

Uma matriz diagonal é uma matriz quadrada que tem zeros fora das diagonais

$$\mathbf{D} = \begin{pmatrix} d_1 & 0 & \dots & 0 \\ 0 & d_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & d_p \end{pmatrix}_{p \times p}$$

Muitas vezes escrevemos  $\mathbf{D} = \text{diag}(d_1, \dots, d_p)$  para definir uma matriz diagonal

A matriz identidade de ordem  $p$  é uma matriz  $p \times p$  que tem uns ao longo do diagonal principal e zeros fora das diagonais

$$I_p = \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix}_{p \times p}$$

Note que  $I_p$  é um caso especial de uma matriz diagonal.

# Matrizes de zeros e uns

Um vetor ou matriz de zeros será denotado por

$$\mathbf{o}_n = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}_{n \times 1} \quad \mathbf{O}_{n \times n} = \begin{pmatrix} 0 & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{pmatrix}_{n \times p}$$

Um vetor ou matriz de uns será denotado por

$$\mathbf{1}_n = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}_{n \times 1} \quad \mathbf{1}_{n \times n} = \begin{pmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \dots & 1 \end{pmatrix}_{n \times p}$$

# Soma e diferença de matriz: definição

- Dado duas matrizes da mesma ordem  $\mathbf{A} = (a_{ij})_{n \times p}$  e  $\mathbf{B} = (b_{ij})_{n \times p}$  a soma  $\mathbf{A} + \mathbf{B}$  resulta a matriz  $\mathbf{C} = (c_{ij})_{n \times p}$  tal que  $c_{ij} = a_{ij} + b_{ij}$ .
- Dado duas matrizes da mesma ordem  $\mathbf{A} = (a_{ij})_{n \times p}$  e  $\mathbf{B} = (b_{ij})_{n \times p}$  a diferença  $\mathbf{A} - \mathbf{B}$  resulta a matriz  $\mathbf{C} = (c_{ij})_{n \times p}$  tal que  $c_{ij} = a_{ij} - b_{ij}$ .

Nota: adição e diferença de matriz são definidas apenas para duas matrizes da mesma ordem.



## Soma e diferença de matriz: definição

Dado  $\mathbf{A} = \begin{pmatrix} 1 & 4 & 8 & 13 \\ 2 & 8 & 11 & 2 \\ 7 & 2 & 6 & 9 \end{pmatrix}$  e  $\mathbf{B} = \begin{pmatrix} 5 & 6 & 1 & 7 \\ 1 & 3 & 0 & 2 \\ 2 & 5 & 3 & 5 \end{pmatrix}$  temos

$$\mathbf{A} + \mathbf{B} = \begin{pmatrix} 1+5 & 4+6 & 8+1 & 13+7 \\ 2+1 & 8+3 & 11+0 & 2+2 \\ 7+2 & 2+5 & 6+3 & 9+5 \end{pmatrix} = \begin{pmatrix} 6 & 10 & 9 & 20 \\ 3 & 11 & 11 & 4 \\ 9 & 7 & 9 & 14 \end{pmatrix}$$

$$\mathbf{A} - \mathbf{B} = \begin{pmatrix} 1-5 & 4-6 & 8-1 & 13-7 \\ 2-1 & 8-3 & 11-0 & 2-2 \\ 7-2 & 2-5 & 6-3 & 9-5 \end{pmatrix} = \begin{pmatrix} -4 & -2 & 7 & 6 \\ 1 & 5 & 11 & 0 \\ 0 & -3 & 3 & 4 \end{pmatrix}$$

# Produto interno entre dois vetores

Sejam  $\mathbf{v} = \mathbf{v}_{s \times 1}$  e  $\mathbf{w} = \mathbf{w}_{s \times 1}$ . Define-se o produto interno de dois vetores como

$$\mathbf{v}^\top \mathbf{w} = \begin{pmatrix} v_1 & v_2 & \dots & v_s \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_s \end{pmatrix} = v_1 w_1 + v_2 w_2 + \dots + v_s w_s \in \mathbb{R}.$$

note que os  $\mathbf{v}$  e  $\mathbf{w}$  são da mesma ordem.

# Produto externo entre dois vetores

Sejam  $\mathbf{v} = \mathbf{v}_{m \times 1}$  e  $\mathbf{w} = \mathbf{w}_{n \times 1}$ . Define-se o produto externo de dois vetores como

$$\mathbf{vw}^T = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_m \end{pmatrix} (w_1 \quad w_2 \quad \dots \quad w_n) = \begin{pmatrix} v_1 w_1 & v_1 w_2 & \dots & v_1 w_n \\ v_2 w_1 & v_2 w_2 & \dots & v_2 w_n \\ \vdots & \vdots & \ddots & \vdots \\ v_m w_1 & v_m w_2 & \dots & v_m w_n \end{pmatrix}_{m \times n}$$

note que os  $\mathbf{v}$  e  $\mathbf{w}$  têm diferente ordens.

# Produto de Matriz-escalar

Seja  $\mathbf{A} = \{a_{ij}\}_{n \times m}$  uma matriz de ordem  $n \times m$  e  $c \in \mathbb{R}$  um escalar. Define-se o produto de uma matriz por um escalar como

$$c \mathbf{A} = \mathbf{A} c = \begin{pmatrix} c a_{11} & c a_{12} & \dots & c a_{1m} \\ c a_{21} & c a_{22} & \dots & c a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ c a_{n1} & c a_{n2} & \dots & c a_{nm} \end{pmatrix}_{n \times m}$$

que é uma matriz  $\mathbf{C} = \{c_{ij}\}_{n \times m}$  tal que  $c_{ij} = ca_{ij}$ .

# Produto de duas matrizes

Sejam  $A = \{a_{ij}\}_{n \times m}$  e  $B = \{b_{jk}\}_{m \times p}$  duas matrizes. O produto  $AB$  é uma matriz  $n \times p$  em que

$$\mathbf{AB} = \begin{pmatrix} \sum_{i=1}^m a_{1i}b_{i1} & \dots & \sum_{i=1}^m a_{1i}b_{ip} \\ \vdots & \ddots & \vdots \\ \sum_{i=1}^m a_{ni}b_{i1} & \dots & \sum_{i=1}^m a_{ni}b_{ip} \end{pmatrix}_{n \times p} \quad (1)$$

Observe que o número de linhas de  $B$  deve corresponder ao número de colunas de  $A$  (ou seja,  $m$ ), e observe que  $\mathbf{AB} \neq \mathbf{BA}$  mesmo se ambos os produtos forem definidos.

# Matriz ortogonal e idempotente

- Uma matriz quadrada  $\mathbf{A}$  é chamada ortogonal se  $\mathbf{A}\mathbf{A}^\top = \mathbf{A}^\top\mathbf{A} = \mathbf{I}$ .
- Uma matriz quadrada  $\mathbf{A}$  é chamada idempotente se  $\mathbf{A}\mathbf{A} = \mathbf{A}$ .

## Exemplo

As seguintes matrizes aparecem frequentemente em análise multivariada

- Uma matriz de rotação  $R = \begin{pmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{pmatrix}$  é ortogonal.
- A matriz de centralização  $C = \mathbf{I}_n + \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top$  e a matriz de projeção  $P_A = A(A^\top A)^{-1}A^\top$  são idempotentes.

# Determinante de uma matriz

O determinante é um conceito importante de álgebra matricial. Para uma matriz quadrada  $\mathbf{A} = \{a_{ij}\}_{p \times p}$ , é definido como

$$\det(\mathbf{A}) = |\mathbf{A}| = \sum (-1)^{|\tau|} a_{1\tau(1)} \dots a_{p\tau(p)},$$

a soma é sobre todas as permutações  $\tau$  de  $\{1, 2, \dots, p\}$  e  $|\tau| = 0$  se a permutação pode ser escrita como um produto de um número par de transposições e  $|\tau| = 1$  caso contrário.

## Exemplo

No caso que  $p = 2$ ,  $\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$  podemos permutar os dígitos "1" e "2" uma vez ou não. Então

$$\det(\mathbf{A}) = a_{11}a_{22} - a_{12}a_{21}.$$

- 1 Para matrizes  $\mathbf{A}_{n \times n}$  e  $b \in R$ ,  $\det(b\mathbf{A}) = b^n \det(\mathbf{A})$
- 2 Para matrizes  $\mathbf{A}_{n \times n}$  e  $\mathbf{B}_{n \times n} \Rightarrow \det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B})$ .
- 3 Para matrizes  $\mathbf{A}_{p \times q}$  e  $\mathbf{B}_{q \times p} \Rightarrow \det(\mathbf{I}_p - \mathbf{AB}) = \det(\mathbf{I}_q - \mathbf{BA})$
- 4 Se  $\mathbf{A}_{p \times p}$  é ortogonal então  $\det(\mathbf{A}) = \pm 1$ .
- 5  $\det(\mathbf{A}) \neq 0 \Rightarrow \mathbf{A}$  é não singular.



Se  $\mathbf{A}_{p \times p}$  é não singular existe a matriz inversa da matriz, denotado por  $\mathbf{A}^{-1}$  que satisfaz  $\mathbf{A}\mathbf{A}^{-1} = \mathbf{I}_p$

Algumas propriedades

- 1  $(\mathbf{A}^{-1})^{-1} = \mathbf{A}$ .
- 2  $\mathbf{A}_{n \times n}$  e  $\mathbf{B}_{n \times n}$  não singulares  $\Rightarrow (\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$ .
- 3  $\mathbf{A}_{n \times n}$  não singular e  $k \neq 0$  um escalar  $\Rightarrow (k\mathbf{A})^{-1} = (1/k)\mathbf{A}^{-1}$ .
- 4 Se  $\mathbf{A}$  é uma matriz ortogonal  $\mathbf{A}^{-1} = \mathbf{A}^T$ .

# Autovetores e Autovalores de uma Matriz

Dada a matriz  $\mathbf{A}_{p \times p}$  considere a transformação linear:  $\mathbf{w} = \mathbf{A}\mathbf{u}$  onde  $\mathbf{u}$  e  $\mathbf{w}$  são vetores de um espaço  $p$ -dimensional.

## Definição

*Um vetor  $\mathbf{u} \neq \mathbf{0}$  é dito ser autovetor da matriz  $\mathbf{A}_{p \times p}$  se a transformação linear deste vetor é colinear a este vetor. Ou seja, se  $\mathbf{A}\mathbf{u} = \lambda\mathbf{u}$ . O escalar  $\lambda$  é chamado de autovalor da matriz  $\mathbf{A}$  correspondente ao autovetor  $\mathbf{u}$ .*

# Autovetores e Autovalores de uma Matriz

Dada a matriz  $\mathbf{A}_{p \times p}$  considere a transformação linear:  $\mathbf{w} = \mathbf{A}\mathbf{u}$  onde  $\mathbf{u}$  e  $\mathbf{w}$  são vetores de um espaço  $p$ -dimensional.

## Definição

*Um vetor  $\mathbf{u} \neq \mathbf{0}$  é dito ser autovetor da matriz  $\mathbf{A}_{p \times p}$  se a transformação linear deste vetor é colinear a este vetor. Ou seja, se  $\mathbf{A}\mathbf{u} = \lambda\mathbf{u}$ . O escalar  $\lambda$  é chamado de autovalor da matriz  $\mathbf{A}$  correspondente ao autovetor  $\mathbf{u}$ .*

- Note que  $(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{u} = \mathbf{0}$ , a equação tem solução diferente da nula ( $\mathbf{u} \neq \mathbf{0}$ ) se e somente se, seu determinante é zero.
- $\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$ , é chamada equação característica e o polinômio em  $\lambda$  definido por ela se chama polinômio característico.
- As raízes deste polinômio são os autovalores da matriz  $\mathbf{A}$
- Cada autovalor  $\lambda_j$  determina um autovetor e é solução das equações:  $(\mathbf{A} - \lambda_j\mathbf{I}_p)\mathbf{u} = \mathbf{0}$

# Autovetores e Autovalores de uma Matriz: Exemplo

Encontre os autovetores e autovalores da matriz  $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$  Primeiro devemos encontrar os autovalores solução do polinômio característico:  $\det(\mathbf{A} - \lambda \mathbf{I}_2) = 0$

$$\det \begin{pmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{pmatrix} = 0 \iff (2 - \lambda)^2 - 1 = 0 \iff \lambda_1 = 1, \lambda_2 = 3.$$

Dados os autovalores, os autovetores devem ser encontrados substituindo cada autovalor na equação:  $(\mathbf{A} - \lambda_j \mathbf{I}_2) \mathbf{u} = \mathbf{0}$

Para  $\lambda_1 = 1$  segue  $\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \iff u_1 + u_2 = 0$  ou  $u_1 = -u_2$  onde  $u_1 = c \neq 0$  é uma constante arbitrária. O autovetor  $\mathbf{u}_1$  correspondente a  $\lambda_1$  é  $\mathbf{u}_1 = \begin{pmatrix} c \\ -c \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$  se  $c = 1$

# Autovetores e Autovalores de uma Matriz: Exemplo

Para  $\lambda_1 = 3$  segue  $\begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \iff u_1 - u_2 = 0$  ou  $u_1 = u_2$  onde  $u_1 = c \neq 0$  é uma constante arbitrária. O autovetor  $\mathbf{u}_2$  correspondente a  $\lambda_2$  é  $\mathbf{u}_2 = \begin{pmatrix} c \\ c \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$  se  $c = 1$ .

# Autovetores e Autovalores de uma Matriz: Propriedades

Suponha que a matriz  $\mathbf{A}$  tenha os autovalores  $\lambda_1, \dots, \lambda_p$ . Seja  $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$ . Então

$$|\mathbf{A}| = |\Lambda| = \prod_{i=1}^n \lambda_i.$$

$$\text{tr}(\mathbf{A}) = \text{tr}(\Lambda) = \sum_{i=1}^n \lambda_i$$

Se  $\mathbf{A}$  é uma matriz idempotente, então

$$\text{tr}(\mathbf{A}) = \text{rank}(\mathbf{A}) = \text{número de autovalores} \neq 0$$

Se  $\mathbf{A}$  for simétrico, então seus autovalores são todos reais

# Descomposição de matrizes

- Uma decomposição de matriz decompõe (ou seja, separa) uma determinada matriz em uma multiplicação de matriz de duas (ou mais) matrizes mais simples.
- As decomposições de matriz são úteis:
  - Resolução de sistemas de equações;
  - Encontrar características importantes dos dados.
- Discutiremos brevemente quatro decomposições de matriz:
  - Decomposição espectral
  - Decomposição de Cholesky
  - Decomposição QR
  - Decomposição em valor singular (singular value decomposition, SVD)

# Decomposição espectral ( de autovalor)

A decomposição espectral (DE) decompõe uma matriz simétrica  $\mathbf{A} = \{a_{ij}\}_{n \times n}$  em um produto de três matrizes:

$$\mathbf{A} = \mathbf{\Gamma} \mathbf{\Lambda} \mathbf{\Gamma}^\top$$

tal que

- $\mathbf{\Gamma} = (\gamma_1, \dots, \gamma_n)_{n \times n}$  onde  $\gamma_j$  é  $j$ -ésimo autovetor;
- $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$ , onde  $\lambda_j$  é o  $j$ -ésimo autovalor.
- os autovalores são ordenados  $\lambda_1 > \lambda_2 > \dots, \lambda_n$

Note que  $\mathbf{\Gamma}$  é uma matriz ortogonal, ou seja  $\mathbf{\Gamma}^\top \mathbf{\Gamma} = \mathbf{\Gamma} \mathbf{\Gamma}^\top = \mathbf{I}_n$



A DE da matriz  $A$  simétrica tem-se

$$A = \mathbf{\Gamma} \mathbf{\Lambda} \mathbf{\Gamma}^\top = \lambda_1 \gamma_1 \gamma_1^\top + \dots + \lambda_k \gamma_k \gamma_k^\top = \sum_{i=1}^k \lambda_i \gamma_i \gamma_i^\top$$

onde  $\mathbf{\Gamma} = (\gamma_1 \dots \gamma_k)$ .

Note que

- $A^{-1} = \mathbf{\Gamma} \mathbf{\Lambda}^{-1} \mathbf{\Gamma}^\top = \sum_{i=1}^k \frac{1}{\lambda_i} \gamma_i \gamma_i^\top$ , já que

$$(\mathbf{\Gamma} \mathbf{\Lambda} \mathbf{\Gamma}^\top)(\mathbf{\Gamma} \mathbf{\Lambda}^{-1} \mathbf{\Gamma}^\top) = \mathbf{\Gamma} \mathbf{\Lambda} \mathbf{\Gamma}^\top \mathbf{\Gamma} \mathbf{\Lambda}^{-1} \mathbf{\Gamma}^\top = I.$$

## Definição

A raiz quadrada de  $A$  é denotada por  $A^{1/2}$  e pode ser escrita na forma

$$A^{1/2} = \sum_{i=1}^k \sqrt{\lambda_i} \gamma_i \gamma_i^\top \text{ e tem as}$$

## Propriedades

- 1  $(A^{1/2})^\top = A^{1/2}$  (simétrica),
- 2  $A^{1/2} A^{1/2} = A$ ,
- 3  $(A^{1/2})^{-1} = \Gamma \Lambda^{-1/2} \Gamma^\top$ ,
- 4  $A^{1/2} (A^{1/2})^{-1} = I$ ,
- 5  $A^{-1/2} A^{-1/2} = A^{-1}$  em que  $A^{-1/2} = (A^{1/2})^{-1}$ .

# Decomposição de Cholesky

A decomposição de Cholesky (DC) decompõe uma matriz definida positiva  $\mathbf{A} = \{a_{ij}\}_{n \times n}$  em um produto de duas matrizes:

$$\mathbf{A} = \mathbf{L}\mathbf{L}^\top$$

onde

$$\mathbf{L} = \begin{pmatrix} l_{11} & 0 & \dots & 0 \\ l_{21} & l_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \dots & l_{nn} \end{pmatrix}$$

é uma matriz triangular inferior (esquerda)

# Decomposição QR

A decomposição QR (DQR) decompõe qualquer matriz (ou seja,  $n \geq p$ )  $\mathbf{A} = \{a_{ij}\}_{n \times p}$  em um produto de duas matrizes:

$$\begin{aligned}\mathbf{A} &= \mathbf{QR} \\ (\mathbf{Q}_1, \mathbf{Q}_2) &\begin{pmatrix} \mathbf{R}_1 \\ \mathbf{0}_{(n-p) \times p} \end{pmatrix} \\ &= \mathbf{Q}_1 \mathbf{R}_1\end{aligned}$$

tal que

- $\mathbf{Q}$  é uma matriz não singular

- $\mathbf{R}_1 = \begin{pmatrix} r_{11} & r_{12} & \dots & r_{1p} \\ 0 & r_{22} & \dots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & r_{pp} \end{pmatrix}_{p \times p}$  é a matriz triangular superior  
(direita)

# Decomposição em valor singular

A decomposição em valor singular (DVS) decompõe qualquer matriz  $\mathbf{A} = \{a_{ij}\}_{n \times p}$  em um produto de três matrizes

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^T$$

onde  $\mathbf{U}_{n \times r}$  e  $\mathbf{V}_{p \times r}$  e ambos  $\mathbf{U}$  e  $\mathbf{V}$  são colunas ortonormais,  $\mathbf{V}^T \mathbf{V} = \mathbf{U}^T \mathbf{U} = \mathbf{I}_r$  e  $\mathbf{\Lambda} = \text{diag}(\lambda_1^{1/2}, \dots, \lambda_r^{1/2})$  e  $\lambda_j > 0$ . Os valores  $\lambda_1, \dots, \lambda_r$  são os autovalores diferentes de zero das matrizes  $\mathbf{A}^T \mathbf{A}$  e  $\mathbf{A}\mathbf{A}^T$ .  $\mathbf{U}$  e  $\mathbf{V}$  consistem nos  $r$  autovetores correspondentes a essas matrizes.

# Classificação de matrizes

Uma forma quadrática  $Q(\mathbf{x})$  é construída a partir de uma matriz simétrica  $\mathbf{A}_{p \times p}$  e um vetor  $\mathbf{x} \in R^p$ .

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i x_j$$

A matriz simétrica  $\mathbf{A}_{p \times p}$  pode ser

- 1 positiva definida, se  $Q(\mathbf{x}) > 0 \forall \mathbf{x} \neq \mathbf{0}$
- 2 positiva semidefinida, se  $Q(\mathbf{x}) \geq 0$  para todo  $\mathbf{x} \neq \mathbf{0}$
- 3 negativa definida, se  $Q(\mathbf{x}) < 0 \forall \mathbf{x} \neq \mathbf{0}$
- 4 negativa semidefinida, se  $Q(\mathbf{x}) \leq 0$  para todo  $\mathbf{x} \neq \mathbf{0}$

Note que  $Q(\mathbf{x}) > 0$  para algum  $\mathbf{x}$  e  $Q(\mathbf{x}) < 0$  outro  $\mathbf{x}$  então a matriz  $\mathbf{A}$  é dito matriz indefinida.

A matriz  $\mathbf{A} = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$  é positiva definida

$$\begin{aligned} Q(x_1, x_2) &= (x_1, x_2) \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\ &= 2x_1^2 - 2x_1x_2 + 2x_2^2 \\ &= x_1^2 + x_2^2 + (x_1 - x_2)^2 \\ &\geq 0 \end{aligned}$$

a igualdade vale quando  $x_1 = x_2 = 0$ .

Seja  $\lambda_j$  o  $j$ -ésimo autovalor de  $\mathbf{A}$  para  $j \in \{1, \dots, n\}$

- 1 Se  $\mathbf{A}$  for positiva definida, então  $\lambda_j > 0 \forall j$
- 2 Se  $\mathbf{A}$  for positivo semi-definido, então  $\lambda_j \geq 0 \forall j$
- 3 Se  $\mathbf{A}$  for negativa definida, então  $\lambda_j < 0 \forall j$
- 4 Se  $\mathbf{A}$  for negativa semidefinida, então  $\lambda_j \leq 0 \forall j$
- 5 Se  $\mathbf{A}$  for indefinido, então  $\lambda_i > 0$  e  $\lambda_j < 0$  para algum  $i \neq j$



# Produto de Kronecker

- Sejam  $A_{m \times n} = (a_{ij})$  e  $B_{p \times q} = (b_{ij})$ .
- O produto de Kronecker entre  $A$  e  $B$  é definido por

$$(A \otimes B)_{mp \times nq} = (a_{ij} B).$$

# Propriedades do produto de Kronecker

- ❶  $0 \otimes A = A \otimes 0 = 0$
- ❷  $(A + B) \otimes C = (A \otimes C) + (B \otimes C)$
- ❸  $A \otimes (B + C) = (A \otimes B) + (A \otimes C)$
- ❹  $aA \otimes bB = ab(A \otimes B)$ , com  $a, b \in \mathbb{R}$
- ❺  $(AB) \otimes (CD) = (A \otimes C)(B \otimes D)$
- ❻  $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$  se  $A^{-1}$  e  $B^{-1}$  existirem
- ❼  $(A \otimes B)^{\top} = A^{\top} \otimes B^{\top}$
- ❽  $(A \otimes B)(A^{-1} \otimes B^{-1}) = I$
- ❾  $A \otimes (B \otimes C) = (A \otimes B) \otimes C.$

O operador  $\text{vec}$  cria um vetor coluna a partir de uma matriz  $\mathbf{A}$ , empilhando os vetores coluna de  $\mathbf{A} = (\mathbf{a}_1, \dots, \mathbf{a}_n)$ , assim

$$\text{vec}(\mathbf{A}) = \begin{pmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_n \end{pmatrix}$$

Propriedades

- $\text{vec}(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A})\text{vec}(\mathbf{X})$
- $\text{tr}(\mathbf{AB}) = \text{vec}(\mathbf{A}^\top)^\top \text{vec}(\mathbf{B})$ .
- $\text{vec}(\mathbf{aa}^\top) = \mathbf{a} \otimes \mathbf{a}$ .

# Operações com matrizes em blocos

Sejam  $A, B, C, \dots$  matrizes com dimensões adequadas em cada caso.

1

$$\begin{bmatrix} A & B & C \\ D & E & F \end{bmatrix} + \begin{bmatrix} A^* & B^* & C^* \\ D^* & E^* & F^* \end{bmatrix} = \begin{bmatrix} A + A^* & B + B^* & C + C^* \\ D + D^* & E + E^* & F + F^* \end{bmatrix},$$

desde que as somas sejam possíveis.

# Operações com matrizes em blocos

Sejam  $A, B, C, \dots$  matrizes com dimensões adequadas em cada caso.

1

$$\begin{bmatrix} A & B & C \\ D & E & F \end{bmatrix} + \begin{bmatrix} A^* & B^* & C^* \\ D^* & E^* & F^* \end{bmatrix} = \begin{bmatrix} A + A^* & B + B^* & C + C^* \\ D + D^* & E + E^* & F + F^* \end{bmatrix},$$

desde que as somas sejam possíveis.

2

$$\begin{bmatrix} P & Q \\ R & S \end{bmatrix} \begin{bmatrix} E \\ G \end{bmatrix} = \begin{bmatrix} PE + QG \\ RE + SG \end{bmatrix},$$

desde que os produtos sejam possíveis.

# Operações com matrizes em blocos

Sejam  $A, B, C, \dots$  matrizes com dimensões adequadas em cada caso.

1

$$\begin{bmatrix} A & B & C \\ D & E & F \end{bmatrix} + \begin{bmatrix} A^* & B^* & C^* \\ D^* & E^* & F^* \end{bmatrix} = \begin{bmatrix} A + A^* & B + B^* & C + C^* \\ D + D^* & E + E^* & F + F^* \end{bmatrix},$$

desde que as somas sejam possíveis.

2

$$\begin{bmatrix} P & Q \\ R & S \end{bmatrix} \begin{bmatrix} E \\ G \end{bmatrix} = \begin{bmatrix} PE + QG \\ RE + SG \end{bmatrix},$$

desde que os produtos sejam possíveis.

3

$$H = \begin{bmatrix} A & B \\ C & D \end{bmatrix}_{m \times n} \Rightarrow H^T = \begin{bmatrix} A^T & C^T \\ B^T & D^T \end{bmatrix}_{n \times m}$$

# Inversas de matrizes em blocos

Seja  $B$  uma matriz particionada em blocos,

$$B = \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix}$$

em que  $B_{11}$  e  $B_{22}$  são matrizes quadradas não-singulares.  
Então

$$B^{-1} = \begin{bmatrix} (B_{11} - B_{12}B_{22}^{-1}B_{21})^{-1} & -B_{11}^{-1}B_{12}(B_{22} - B_{21}B_{11}^{-1}B_{12})^{-1} \\ -B_{22}^{-1}B_{21}(B_{11} - B_{12}B_{22}^{-1}B_{21})^{-1} & (B_{22} - B_{21}B_{11}^{-1}B_{12})^{-1} \end{bmatrix}$$

e

$$|B| = |B_{22}||B_{11} - B_{12}B_{22}^{-1}B_{21}| = |B_{11}||B_{22} - B_{21}B_{11}^{-1}B_{12}|$$

Seja  $B$  uma **matriz bloco diagonal**

$$B = \begin{bmatrix} B_{11} & 0 & 0 \\ 0 & B_{22} & 0 \\ 0 & 0 & B_{33} \end{bmatrix}$$

em que  $B_{11}$ ,  $B_{22}$  e  $B_{33}$  são matrizes quadradas não-singulares.

Então 
$$B^{-1} = \begin{bmatrix} B_{11}^{-1} & 0 & 0 \\ 0 & B_{22}^{-1} & 0 \\ 0 & 0 & B_{33}^{-1} \end{bmatrix}$$

e 
$$|B| = |B_{11}||B_{22}||B_{33}|.$$

O resultado vale para matrizes bloco diagonal de maior dimensão.



# Álgebra Matricial com R

```
(x<-1:12)
[1] 1 2 3 4 5 6 7 8 9 10 11 12
> (A<- matrix(x,nrow=3,ncol=4))
      [,1] [,2] [,3] [,4]
[1,]    1    4    7   10
[2,]    2    5    8   11
[3,]    3    6    9   12

> (b=10)
[1] 10
> (b*x)
[1] 10 20 30 40 50 60 70 80 90 100 110 120
> (b*A)
      [,1] [,2] [,3] [,4]
[1,]   10   40   70  100
[2,]   20   50   80  110
[3,]   30   60   90  120
```

# Álgebra Matricial com R

- Lembre-se: a multiplicação escalar é realizada usando: `*`
- Em contraste, a multiplicação da matriz é realizada usando: `% * %`

```
> x = 1:9
> y = 9:1
> X = matrix(x,3,3)
> Y = matrix(y,3,3)
> X
[,1] [,2] [,3]
[1,] 1 4 7
[2,] 2 5 8
[3,] 3 6 9
> Y
[,1] [,2] [,3]
[1,] 9 6 3
[2,] 8 5 2
[3,] 7 4 1
```

```
> X*Y
      [,1] [,2] [,3]
[1,] 9 24 21
[2,] 16 25 16
[3,] 21 24 9
> X%*%Y
      [,1] [,2] [,3]
[1,] 90 54 18
[2,] 114 69 24
[3,] 138 84 30
```

# Álgebra Matricial com R: Mensagens de Erro

```
> x = 1:6
> y = 6:1
> X = matrix(x,2,3)
> Y = matrix(y,3,2)
> X
[,1] [,2] [,3]
[1,] 1    3    5
[2,] 2    4    6
> Y
[,1] [,2]
[1,] 6    3
[2,] 5    2
[3,] 4    1
```

```
> X*Y
Error in X * Y :
  arrays de dimensão não compatível

> X%%*%Y
      [,1] [,2]
[1,] 41   14
[2,] 56   20
```

# Função transposta

Para obter a transposta de uma matriz em R, usamos a função *t*.

```
> X = matrix(1:6,2,3)
```

```
> X
```

	[,1]	[,2]	[,3]
[1,]	1	3	5
[2,]	2	4	6

```
> t(X)
```

	[,1]	[,2]
[1,]	1	2
[2,]	3	4
[3,]	5	6

# Função dimensão

Para obter a dimensão de uma matriz em R, usamos a função *dim*.

```
> X = matrix(1:6,2,3)
```

```
> X
```

	[,1]	[,2]	[,3]
[1,]	1	3	5
[2,]	2	4	6

```
> dim(X)
```

```
[1] 2 3
```

```
> dim(t(X))
```

```
[1] 3 2
```

# Função produto cruzado

Dado  $\mathbf{X} = \{x_{ij}\}_{n \times p}$  e  $\mathbf{Y} = \{y_{ij}\}_{n \times p}$  pode-se obter o produto cruzado  $\mathbf{X}^T \mathbf{Y}$  usando a função: *crossprod*

```
> X = matrix(1:6,3,2)
```

```
> Y = matrix(1:9,3,3)
```

```
> crossprod(X,Y)
```

```
  [,1] [,2] [,3]  
[1,]   14   32   50  
[2,]   32   77  122
```

```
> t(X)%*%Y
```

```
  [,1] [,2] [,3]  
[1,]   14   32   50  
[2,]   32   77  122
```

- Observe que *crossprod* produz o mesmo resultado que usar transposta e símbolo de multiplicação de matriz.
- No entanto, é preferível *crossprod* porque é mais rápido

# Função produto cruzado-transposto

Dado  $\mathbf{X} = \{x_{ij}\}_{n \times p}$  e  $\mathbf{Y} = \{y_{ij}\}_{n \times p}$  pode-se obter o produto cruzado transposto  $\mathbf{XY}^T$  usando a função: *tcrossprod*

```
> X = matrix(1:6,2,3)
```

```
> Y = matrix(1:9,3,3)
```

```
> tcrossprod(X,Y)
```

```
      [,1] [,2] [,3]  
[1,]   48   57   66  
[2,]   60   72   84
```

```
> X %*% t(Y)
```

```
      [,1] [,2] [,3]  
[1,]   48   57   66  
[2,]   60   72   84
```

- Observe que *tcrossprod* produz o mesmo resultado que usar transposta e símbolo de multiplicação de matriz.
- No entanto, é preferível *tcrossprod* porque é mais rápido

# Funções de soma de linha e coluna

Podemos obter somas de linha e coluna usando o funções *rowSums* e *colSums*

```
> X = matrix(1:6,2,3)
> X
[,1] [,2] [,3]
[1,]    1    3    5
[2,]    2    4    6
> rowSums(X)
[1]  9 12
> colSums(X)
[1]  3  7 11
```



# Funções média de linha e coluna

Podemos obter médias de linha e coluna usando o funções *rowMeans* e *colMeans*

```
> X = matrix(1:6,2,3)
> X
[,1] [,2] [,3]
[1,] 1 3 5
[2,] 2 4 6
> rowMeans(X)
[1] 3 4
> colMeans(X)
[1] 1.5 3.5 5.5
```

# Traço de uma matriz

```
> X <- matrix(data = 1:9, ncol = 3)
> X
      [,1] [,2] [,3]
[1,]     1     4     7
[2,]     2     5     8
[3,]     3     6     9
> sum(diag(X))
[1] 15
> X <- matrix(data = 1:6, ncol = 3)
> X
      [,1] [,2] [,3]
[1,]     1     3     5
[2,]     2     4     6
> sum(diag(X))
[1] 5
```

# Função diagonal

A função *diag* tem múltiplos propósitos :

- Se você inserir uma matriz quadrada, *diag* retorna os elementos diagonais
- Se você inserir um vetor, *diag* cria uma matriz diagonal
- Se você inserir um escalar, o *diag* criará uma matriz de identidade

```
> X = matrix(1:4,2,2)
> X
[,1] [,2]
[1,] 1    3
[2,] 2    4
>
> diag(X)
[1] 1 4
```

```
> diag(1:3)
      [,1] [,2] [,3]
[1,] 1    0    0
[2,] 0    2    0
[3,] 0    0    3

> diag(3)
      [,1] [,2] [,3]
[1,] 1    0    0
[2,] 0    1    0
[3,] 0    0    1
```

# Funções para decomposições de matrizes

R tem funções integradas para decomposições de matrizes:

- Descomposição espectral: *eigen*
- Decomposição de Cholesky : *chol*
- Decomposição QR: : *qr*
- Decomposição em valor singular (singular value decomposition, SVD): *svd*

# Descomposição espectral

```
> X = matrix(1:9,3,3)
> X = crossprod(X)
> x eig = eigen(X,symmetric=TRUE)
> x eig$val
[1] 2.838586e+02 1.141413e+00 6.308738e-15
> x eig$vector
      [,1]      [,2]      [,3]
[1,] -0.2148372  0.8872307  0.4082483
[2,] -0.5205874  0.2496440 -0.8164966
[3,] -0.8263375 -0.3879428  0.4082483
> Xhat = x eig$vec %*% diag(x eig$val) %*% t(x eig$vec)

> sum( (X - Xhat)^2 )
[1] 1.178874e-26
```

# Descomposição Cholesky

```
> set.seed(11)
> X = matrix(runif(9),3,3)
> X = crossprod(X)
> xchol = chol(X)
> t(xchol)
      [,1]      [,2]      [,3]
[1,] 0.5810238 0.0000000 0.0000000
[2,] 0.8458902 0.4478715 0.0000000
[3,] 0.8154978 0.3819997 0.2371446
> Xhat = crossprod(xchol)
> sum( (X - Xhat)^2 )
[1] 0
```

# Descomposição QR

```
> X = matrix(1:6,3,2)
> xqr = qr(X)
> Q = qr.Q(xqr)
> Q
[,1]      [,2]
[1,] -0.2672612  0.8728716
[2,] -0.5345225  0.2182179
[3,] -0.8017837 -0.4364358

> R = qr.R(xqr)
> R
[,1]      [,2]
[1,] -3.741657 -8.552360
[2,]  0.000000  1.963961
> Xhat = Q %*% R[,sort(xqr$pivot,index=TRUE)$ix]
> sum( (X - Xhat)^2 )
[1] 1.343529e-30
```

# Descomposição em valor singular

```
> X = matrix(1:6,3,2)
> xsvd = svd(X)
> xsvd
$d
[1] 9.5080320 0.7728696

$u
[,1]      [,2]
[1,] -0.4286671 0.8059639
[2,] -0.5663069 0.1123824
[3,] -0.7039467 -0.5811991

$v
[,1]      [,2]
[1,] -0.3863177 -0.9223658
[2,] -0.9223658 0.3863177

> Xhat = xsvd$u %*% diag(xsvd$d)
          %*% t(xsvd$v)

> Xhat
          [,1] [,2]
[1,]      1    4
[2,]      2    5
[3,]      3    6
> sum( (X - Xhat)^2 )
[1] 1.212874e-29
```



## Posto de uma matriz quadrada

```
> library(matrixcalc)
> A <- diag( seq( 1, 4, 1 ) )
> A
[,1] [,2] [,3] [,4]
[1,] 1 0 0 0
[2,] 0 2 0 0
[3,] 0 0 3 0
[4,] 0 0 0 4
> matrix.rank( A )
[1] 4
> B=matrix(c(1,2,3,6),2)
> B
[,1] [,2]
[1,] 1 3
[2,] 2 6
> matrix.rank(B, method ="qr")
[1] 1
```

# Produto de Kronecker

```
> B = matrix(1:6,3,2)
```

```
> B
```

```
[,1] [,2]  
[1,] 1 4  
[2,] 2 5  
[3,] 3 6
```

```
> C=diag(2)
```

```
> C
```

```
[,1] [,2]  
[1,] 1 0  
[2,] 0 1
```

```
> kronecker(C,B)
```

```
[,1] [,2] [,3] [,4]  
[1,] 1 4 0 0  
[2,] 2 5 0 0  
[3,] 3 6 0 0  
[4,] 0 0 1 4  
[5,] 0 0 2 5  
[6,] 0 0 3 6
```

```
kronecker(B,C)
```

```
[,1] [,2] [,3] [,4]  
[1,] 1 0 4 0  
[2,] 0 1 0 4  
[3,] 2 0 5 0  
[4,] 0 2 0 5  
[5,] 3 0 6 0  
[6,] 0 3 0 6
```

```
> library(matrixcalc)
> set.seed(2)
> D=matrix(rnorm(6),3,2)
> D
```

	[,1]	[,2]
[1,]	-0.8969145	-1.13037567
[2,]	0.1848492	-0.08025176
[3,]	1.5878453	0.13242028

```
> vec(D)
[,1]
[1,] -0.89691455
[2,]  0.18484918
[3,]  1.58784533
[4,] -1.13037567
[5,] -0.08025176
[6,]  0.13242028
```