

# Vetores Aleatórios e Distribuição Normal Multivariada

Vicente G. Cancho  
garibay@icmc.usp.br

# Vetor e Matriz aleatório

- Um vetor aleatório é um vetor cujos elementos são variáveis aleatórias
- Da mesma forma, uma matriz aleatória é uma matriz cujos elementos são variáveis aleatórias
- O valor esperado de uma matriz aleatória (ou vetor) é a matriz (vetor) que consiste nos valores esperados de cada um de seus elementos,
- Especificamente, seja  $\mathbf{X} = \{X_{ij}\}_{n \times p}$  uma matriz aleatória de ordem  $n \times p$ .
- Então, o valor esperado de  $\mathbf{X}$ , denotado por  $E(\mathbf{X})$ , é a matriz de números de ordem  $n \times p$ .

$$E[\mathbf{X}] = \begin{pmatrix} E[X_{11}] & E[X_{12}] & \dots & E[X_{1p}] \\ E[X_{21}] & E[X_{22}] & \dots & E[X_{2p}] \\ \vdots & \vdots & \ddots & \vdots \\ E[X_{n1}] & E[X_{n2}] & \dots & E[X_{np}] \end{pmatrix}$$

onde

$$\mu_{ij} = E[X_{ij}] = \begin{cases} \int_{-\infty}^{\infty} x_{ij} f_{ij}(x_{ij}) dx_{ij}, & \text{se } X_{ij} \text{ é v.a.c com f.d.p. } f_{ij}(x_{ij}) \\ \sum_{x_{ij}} x_{ij} p_{ij}(x_{ij}), & \text{se } X_{ij} \text{ é v.a.d. com f.p. } p_{ij}(x_{ij}) \end{cases}$$

## Preposição

*Sejam  $\mathbf{X}$  e  $\mathbf{Y}$  matrizes aleatórias da mesma dimensão, e sejam  $\mathbf{A}$  e  $\mathbf{B}$  matrizes de constantes (adequadas). Então*

$$\begin{aligned} E[\mathbf{X} + \mathbf{Y}] &= E[\mathbf{X}] + E[\mathbf{Y}] \\ E[\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y}] &= E[\mathbf{A}\mathbf{X}] + E[\mathbf{B}\mathbf{Y}] \end{aligned}$$

# Vetor de Média e Matriz Covariância

Suponha  $\mathbf{X}^\top = (X_1, X_2, \dots, X_p)$ , é um **vetor aleatório** de ordem  $p \times 1$ . Então cada elemento de  $\mathbf{X}$ , é uma variável aleatória.

A **média**  $\mu_i$  e **variância**  $\sigma_i^2 = \sigma_{ii}$ , para  $i = 1, \dots, p$ , são definidos por  $\mu_i = E(X_i)$  e  $\sigma_i^2 = \text{Var}(X_i) = E[(X_i - \mu_i)^2]$  respectivamente.

Especificamente,

$$\mu_i = \begin{cases} \int_{-\infty}^{\infty} x_i f_i(x_i) dx_i, & \text{se } X_i \text{ é v.a. contínua com f.d.p. } f_i(x_i) \\ \sum_{x_i} x_i p_i(x_i), & \text{se } X_i \text{ é v.a. discreta com f.p. } p_i(x_i) \end{cases}$$

# Vetor de Média e Matriz Covariância

$$\sigma_i^2 = \begin{cases} \int_{-\infty}^{\infty} (x_i - \mu_i)^2 f_i(x_i) dx_i, & \text{se } X_i \text{ é v.a. contínua com f.d.p. } f_i(x_i) \\ \sum_{x_i} (x_i - \mu_i)^2 p_i(x_i), & \text{se } X_i \text{ é v.a. discreta com f.p. } p_i(x_i) \end{cases}$$

A **covariância** e a **correlação** (populacionais) entre duas variáveis  $X_i$  e  $X_k$ , com  $i, k = 1, \dots, p$  e  $i \neq k$  são dadas, respectivamente, por

$$\text{Cov}(X_i, X_k) = \sigma_{ik} = E[(X_i - \mu_i)(X_k - \mu_k)] \text{ e}$$

$$\text{Cor}(X_i, X_k) = \rho_{ik} = \frac{\sigma_{ik}}{\sqrt{\sigma_i^2} \sqrt{\sigma_k^2}}$$

# Vetor de Média e Matriz Covariância

Mais especificamente,

$$\sigma_{ik} = \begin{cases} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x_i - \mu_i)(x_k - \mu_k) f_{ik}(x_i, x_k) dx_i dx_k, & \text{contínuo} \\ \sum_{x_i} \sum_{x_k} (x_i - \mu_i)(x_k - \mu_k) p_{ik}(x_i, x_k), & \text{discreto} \end{cases}.$$

# Distribuição conjunta de um vetor aleatório

A distribuição conjunta das  $p$  variáveis aleatórias (v.a.'s)  $X_1, \dots, X_p$  ou do vetor  $\mathbf{X} = (X_1, \dots, X_p)^\top$  é descrito pela **função densidade de probabilidade conjunta** (ou função de probabilidade conjunta no caso discreto) de  $X_1, \dots, X_p$ , dada por

$$f(x_1, \dots, x_p) = f(\mathbf{x}),$$

com

$$\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(u_1, \dots, u_p) du_1 \dots du_p = 1$$

(ou somatória no caso discreto).

# Função distribuição acumulada

Se  $\mathbf{X} = (X_1, \dots, X_p)^\top$  é um vetor aleatório e tem f.d.p.  $f(\mathbf{x}) = f(x_1, \dots, x_p)$ , então a **função distribuição acumulada** de  $\mathbf{x}$  é dada por

$$F(\mathbf{x}) = P(\mathbf{X} \leq \mathbf{x}) = P(X_1 \leq x_1, \dots, X_p \leq x_p)$$

que pode ser calculada no nosso contexto como

$$F(\mathbf{x}) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_p} f(u_1, \dots, u_p) du_1 \dots du_p$$

(no caso discreto substituir por somatórias adequadas)



# Função distribuição acumulada

Se  $\mathbf{X} = (X_1, \dots, X_p)^\top$  é um vetor aleatório e tem f.d.p.  $f(\mathbf{x}) = f(x_1, \dots, x_p)$ , então a **função distribuição acumulada** de  $\mathbf{x}$  é dada por

$$F(\mathbf{x}) = P(\mathbf{X} \leq \mathbf{x}) = P(X_1 \leq x_1, \dots, X_p \leq x_p)$$

que pode ser calculada no nosso contexto como

$$F(\mathbf{x}) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_p} f(u_1, \dots, u_p) du_1 \dots du_p$$

(no caso discreto substituir por somatórias adequadas)

As variáveis aleatórias  $X_i$  e  $X_k$ , são estocasticamente independente se

$$P(X_i \leq x_i, X_k \leq x_k) = P(X_i \leq x_i)P(X_k \leq x_k)$$

para todos os pares possíveis  $(x_i, x_k)$ ,

No caso que  $X_i$  e  $X_k$  são variáveis aleatórias contínuas com f.d.p.  $f_{ik}(x_i, x_k)$ , a condição para a independência é

$$f_{ik}(x_i, x_k) = f_i(x_i)f_k(x_k)$$

para todo par  $(x_i, x_k)$ .

Se tivermos  $p$  variáveis aleatórias contínuas  $X_1, \dots, X_p$ , elas são estatisticamente independentes se a sua f.d.p. conjunta pode ser fatorada como

$$f(\mathbf{x}) = f_1(x_1) \dots f_p(x_p), \forall (x_1, \dots, x_p).$$

A independência tem uma implicação importante:

## Proposição

*Se  $X_i$  e  $X_k$  são independentes, então*

$$\text{Cov}(X_i, X_k) = 0$$

# Vetor de médias e matriz de variâncias e covariâncias

O **vetor de médias** (populacionais) de  $\mathbf{X}$  é  $\mu_{p \times 1}$  e a **matriz de variâncias e covariâncias** (populacionais) de  $\mathbf{X}$  é  $\Sigma_{p \times p}$ , em que

$$\mu = E(\mathbf{X}) = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{pmatrix} = \begin{pmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{pmatrix} \text{ e } \Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1p} \\ & \sigma_2^2 & \dots & \sigma_{2p} \\ & & \ddots & \vdots \\ \text{sim.} & & & \sigma_p^2 \end{pmatrix}$$

Obs: Note que  $\Sigma$  é simétrica pois  $\text{Cov}(X_i, X_k) = \text{Cov}(X_k, X_i)$ , para  $i, j = 1, \dots, p$ .

# Matriz de correlações (populacionais)

A **matriz de correlações** (populacionais) de  $\mathbf{X}$  é  $\boldsymbol{\rho} = \{\rho\}_{p \times p}$ , em que

$$\boldsymbol{\rho} = \text{Cor}(\mathbf{X}) = \begin{pmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ & 1 & \cdots & \rho_{2p} \\ & & \ddots & \vdots \\ \text{sim.} & & & 1 \end{pmatrix}$$

- $\boldsymbol{\rho}$  é uma matriz simétrica
- $-1 \leq \rho_{ik} \leq 1$  para  $i \neq k$  e  $i, k = 1, \dots, p$ .

# Matriz de variâncias e covariâncias (populacionais)

Matricialmente,

$$\text{Cov}(\mathbf{X}) = \Sigma = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^{\top}].$$

Além disso,

$$\text{Cor}(\mathbf{X}) = \boldsymbol{\rho} = (V^{1/2})^{-1}\Sigma(V^{1/2})^{-1} = V^{-1/2}\Sigma V^{-1/2},$$

em que

$$V^{1/2} = \begin{pmatrix} \sqrt{\sigma_{11}} & 0 & \dots & 0 \\ 0 & \sqrt{\sigma_{22}} & \ddots & 0 \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & \sqrt{\sigma_{pp}} \end{pmatrix}$$

# Variância-Covariância: Exemplo

Considere a matriz de variância-covariâncias

$$\Sigma = \begin{pmatrix} 4 & 1 & 2 \\ 1 & 9 & -3 \\ 2 & -3 & 25 \end{pmatrix} = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{12} & \sigma_{22} & \sigma_{23} \\ \sigma_{13} & \sigma_{23} & \sigma_{33} \end{pmatrix}$$

A Matriz

$$V^{1/2} = \begin{pmatrix} \sqrt{4} & 0 & 0 \\ 0 & \sqrt{9} & 0 \\ 0 & 0 & \sqrt{25} \end{pmatrix} = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 5 \end{pmatrix}$$

e

$$V^{-1/2} = \begin{pmatrix} 1/2 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1/5 \end{pmatrix}$$

# Variância-Covariância: Exemplo

A matriz de correlações resulta

$$\begin{aligned}\rho &= V^{-1/2} \Sigma V^{-1/2} \\ &= \begin{pmatrix} 1/2 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1/5 \end{pmatrix} \begin{pmatrix} 4 & 1 & 2 \\ 1 & 9 & -3 \\ 2 & -3 & 25 \end{pmatrix} \begin{pmatrix} 1/2 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1/5 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 1/6 & 1/5 \\ 1/6 & 1 & -1/5 \\ 1/5 & -1/5 & 1 \end{pmatrix}\end{aligned}$$



# Variância e covariância em forma matricial

Sejam  $\mathbf{X}$  e  $\mathbf{Y}$  vetores aleatórios  $p$ -dimensionais com  $E(\mathbf{X}) = \boldsymbol{\mu}_X$  e  $E(\mathbf{Y}) = \boldsymbol{\mu}_Y$ .

Define-se

1

$$\begin{aligned} \text{Var}(\mathbf{X}) &= \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{X} - \boldsymbol{\mu}_X)^\top] \\ &= E[\mathbf{X}^\top \mathbf{X}] - \boldsymbol{\mu}_X^\top \boldsymbol{\mu}_X \end{aligned}$$

2

$$\begin{aligned} \text{Cov}(\mathbf{X}, \mathbf{Y}) &= E[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{Y} - \boldsymbol{\mu}_Y)^\top] \\ &= E[\mathbf{X}^\top \mathbf{Y}] - \boldsymbol{\mu}_X^\top \boldsymbol{\mu}_Y \end{aligned}$$

# Particionando a matriz de covariância

Seja vetor  $\mathbf{X}$  particionada com  $\mathbf{X} = (\mathbf{X}_1^\top, \mathbf{X}_2^\top)^\top$  em  $\mathbf{X}_1$  e  $\mathbf{X}_2$  são vetores de dimensões  $q$  e  $p - q$  respectivamente, ou seja,

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_q \\ \dots \\ X_{q+1} \\ \vdots \\ X_p \end{pmatrix} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix} \text{ e } \boldsymbol{\mu} = \begin{pmatrix} E[X_1] \\ E[X_2] \\ \vdots \\ E[X_q] \\ \dots \\ E[X_{q+1}] \\ \vdots \\ E[X_p] \end{pmatrix} = \begin{pmatrix} E[\mathbf{X}_1] \\ E[\mathbf{X}_2] \end{pmatrix} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}$$

# Particionando a matriz de covariância

A matriz de variância-covariância  $\Sigma$  particionada resulta

$$\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

onde

- $\Sigma_{11}$  é a covariância de  $\mathbf{X}_1$  de ordem  $q \times q$
- $\Sigma_{22}$  é a covariância de  $\mathbf{X}_2$  de ordem  $(p - q) \times p - q$ .
- $\Sigma_{12}$  é de ordem  $q \times (p - 1)$ ,
- $\Sigma_{21}$  é de ordem  $(p - q) \times p$
- $\Sigma_{12} = \Sigma_{21}^\top$  e são covariância de  $\mathbf{X}_1$  e  $\mathbf{X}_2$

# Vetor de Médias e Matriz de Covariância de uma Combinação Linear de Variáveis Aleatórias

## Combinação Linear de $p$ variáveis aleatórias

Se  $\mathbf{X}$  é um vetor de aleatória  $p$ -dimensional e  $\mathbf{c}$  é um vetor de constantes reais de ordem  $p \times 1$ , então a combinação linear

$$\mathbf{c}^\top \mathbf{X} = c_1 X_1 + \cdots + c_p X_p$$

tem média e variância

$$\begin{aligned}\mu &= E[\mathbf{c}^\top \mathbf{X}] = \mathbf{c}^\top E[\mathbf{X}] \text{ e} \\ \sigma^2 &= \text{Var}[\mathbf{c}^\top \mathbf{X}] = \mathbf{c}^\top \text{Var}[\mathbf{X}] \mathbf{c}\end{aligned}$$

respectivamente.

Exercício (mostre)

# Vetor de Médias e Matriz de Covariância de uma Combinação Linear de Variáveis Aleatórias

Considere as  $q$  combinações lineares de  $p$  variáveis aleatórias,

$$Z_1 = c_{11}X_1 + \cdots + c_{1p}X_p$$

$$Z_2 = c_{21}X_1 + \cdots + c_{2p}X_p$$

$$\vdots = \quad \quad \quad \vdots$$

$$Z_q = c_{q1}X_1 + \cdots + c_{qp}X_p$$

ou

$$\mathbf{Z} = \begin{pmatrix} Z_1 \\ Z_2 \\ \vdots \\ Z_q \end{pmatrix} = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1p} \\ c_{21} & c_{22} & \cdots & c_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ c_{q1} & c_{q2} & \cdots & c_{qp} \end{pmatrix} \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_q \end{pmatrix} = \mathbf{C}\mathbf{X}$$

A combinação linear  $\mathbf{Z} = \mathbf{C}\mathbf{X}$  tem

$$\boldsymbol{\mu}_Z = E[\mathbf{Z}] = \mathbf{C}E[\mathbf{X}] = \mathbf{C}\boldsymbol{\mu}_X$$

$$\boldsymbol{\Sigma}_Z = \text{Cov}[\mathbf{Z}] = \mathbf{C}\text{Cov}[\mathbf{X}]\mathbf{C}^\top = \mathbf{C}\boldsymbol{\Sigma}_X\mathbf{C}^\top$$

# Estimadores de $\mu$ e $\Sigma$

Seja  $\mathbf{X}_1, \dots, \mathbf{X}_n$  a.a. de uma população com  $E(\mathbf{X}) = \mu$  e  $Cov(\mathbf{X}) = \Sigma$ , sendo  $\mathbf{X}_i \in R^p$ . Então

①  $\bar{\mathbf{X}}$  (vetor de medias amostrais) é um estimador não-viesado para  $\mu$ , com  $Cov(\bar{\mathbf{X}}) = \frac{\Sigma}{n}$  e

②  $\frac{n}{n-1} \mathbf{S}$  é um estimador não-viesado para  $\Sigma$ , ou seja  
$$E\left(\frac{n}{n-1} \mathbf{S}\right) = \Sigma.$$

onde  $\mathbf{S}$  a matriz de variância amostral.

# A Distribuição Normal Multivariada

# Distribuição Normal Multivariada

Uma variável aleatória contínua  $X$  tem distribuição normal com média  $\mu$  e variância  $\sigma^2$  se sua função densidade é dada por

$$f(x) = (2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{1}{2}(x - \mu)\sigma^{-2}(x - \mu) \right\}, \quad x \in R.$$

- O expoente da densidade normal univariada:  $(x - \mu)(\sigma^2)^{-1}(x - \mu)$  mede a distância quadrada de  $x$  em relação à  $\mu$  em unidade de desvio padrão.
- Esta distância pode ser generalizada para o caso multivariado, com vetor  $\mathbf{X}$  de ordem  $p \times 1$  dada por,

$$(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})$$

onde  $\boldsymbol{\mu}$  é o vetor valores esperados do vetor  $\mathbf{X}$  e  $\boldsymbol{\Sigma}$  a matriz de covariâncias de  $\mathbf{X}$ .



# Distribuição Normal Multivariada

## Definição

Dizemos que um vetor aleatório  $\mathbf{X}$  de ordem  $(p \times 1)$  tem distribuição normal multivariada (ou  $p$ -variada) com vetor de médias  $\boldsymbol{\mu}$  e matriz de variâncias e covariâncias  $\boldsymbol{\Sigma}$  de ordem  $p \times p$ , se sua função de densidade conjunta é dada por

$$f(\mathbf{x}) = (2\pi|\boldsymbol{\Sigma}|)^{-1/2} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right\}, \quad \mathbf{x} \in R^p. \quad (1)$$

$$\text{onde } \boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2p} \\ \vdots & \vdots & \dots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_{pp} \end{pmatrix}.$$

Notação:  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ .

# Distribuição Normal Multivariada

## Exemplo (Normal bivariada)

Para  $p = 2$ , a f.d.p. dada em (1) é dada em termos dos parâmetros individuais

$$f(\mathbf{x}) = (2\pi)^{-1} |\Sigma|^{-1/2} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}, \mathbf{x} \in R^2. \quad (2)$$

onde  $\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ ,  $\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$  e  $\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{pmatrix}$ .

Introduzindo o coeficiente de correlação de  $X_1$  e  $X_2$ ,  $\rho = \frac{\sigma_{12}}{\sqrt{\sigma_{11}\sigma_{22}}} \rightarrow \sigma_{12} = \rho\sqrt{\sigma_{11}\sigma_{22}}$ . Daí temos que,

$$\Sigma^{-1} = \frac{1}{\sigma_{11}\sigma_{22}(1 - \rho^2)} \begin{pmatrix} \sigma_{22} & -\rho\sqrt{\sigma_{11}\sigma_{22}} \\ -\rho\sqrt{\sigma_{11}\sigma_{22}} & \sigma_{11} \end{pmatrix}$$


Logo, a f.d.p. em (2) se reduz a

$$f(x_1, x_2) = \frac{1}{2\pi\sqrt{\sigma_{11}\sigma_{22}(1-\rho^2)}} \exp \left\{ \frac{-1}{2(1-\rho^2)} \left[ \frac{(x_1 - \mu_1)^2}{\sigma_{11}} + \frac{(x_2 - \mu_2)^2}{\sigma_{22}} - 2\rho \left( \frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) \left( \frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right) \right] \right\} \quad (3)$$


# Distribuição normal multivariada

## Distribuição Normal Bivariada


$\rho=0.85$




$\rho=0.5$



$\rho=0.0$



$\rho=-0.85$




A densidade normal é constante em superfícies cujas distâncias quadráticas  $(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})$  são constantes.

Esses padrões são chamados de contornos ou curvas de nível

$$E_c = \{\mathbf{x}; (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c^2\}. \quad (4)$$

Além disso, considere a decomposição espectral de  $\Sigma = \Gamma \Lambda \Gamma^\top$  onde  $\Gamma = (\gamma_1, \dots, \gamma_p)$  e  $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$  com  $\lambda_1 \geq \dots \geq \lambda_p$ . O  $E_c$ , para qualquer  $c$  é um elipsoide centrada em  $\boldsymbol{\mu}$  e tem eixos,  $\pm c\sqrt{\lambda_i}\gamma_i$ , onde  $\Sigma\gamma_i = \lambda_i\gamma_i$ , para  $i = 1, \dots, p$ .

# Contornos da distribuição normal multivariada



## Exemplo

*Considere a distribuição normal bivariada com  $\sigma_{11} = \sigma_{22}$ . Os eixos da elipsóide dados por (4) são fornecidos pelos autovalores e autovetores de  $\Sigma$ . Portanto, para obtê-los, a equação  $|\Sigma - I\lambda| = 0$  deve ser resolvida*

$$\begin{vmatrix} \sigma_{11} - \lambda & \sigma_{12} \\ \sigma_{12} & \sigma_{11} - \lambda \end{vmatrix} = (\sigma_{11} - \lambda)^2 - \sigma_{12}^2 = 0$$

Consequentemente os autovalores resultam:  $\lambda_1 = \sigma_{11} + \sigma_{12}$  e  $\lambda_2 = \sigma_{11} - \sigma_{12}$ . Os autovetores são determinados por :

$$\Sigma \mathbf{e}_i = \lambda_i \mathbf{e}_i, \quad i = 1, 2.$$

# Continuação do exemplo

Para  $i = 1$  tem-se

$$\begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{11} \end{bmatrix} \begin{bmatrix} e_1 \\ e_2 \end{bmatrix} = (\sigma_{11} + \sigma_{12}) \begin{bmatrix} e_1 \\ e_2 \end{bmatrix}$$

ou

$$\sigma_{11}e_1 + \sigma_{12}e_2 = (\sigma_{11} + \sigma_{12})e_1$$

$$\sigma_{12}e_1 + \sigma_{11}e_2 = (\sigma_{11} + \sigma_{12})e_2$$

Essas equações levam ao resultado de que  $e_1 = e_2$ , e após normalização, o primeiro autovetor é:  $\mathbf{e}_1 = \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}$

De forma similar foi obtido o segundo autovetor, o qual é:


$$\mathbf{e}_2 = \begin{bmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{bmatrix}$$



Se a covariância é positiva,  $\lambda_1 = \sigma_{11} + \sigma_{12}$  e o maior autovalor e seu autovetor associado se posiciona ao longo de uma linha de  $45^\circ$  através do ponto  $\boldsymbol{\mu} = [\mu_1, \mu_2]$ . , para qualquer  $\sigma_{12} > 0$ . Os eixos são fornecidos por  $\pm c\sqrt{\lambda_i}\mathbf{e}_i$  ( $i = 1, 2$ ) e estão representados na Figura seguinte.


# Continuação do exemplo

**Figura:** Contornos (curva de nível) de densidade constante para a distribuição normal bivariada com  $\sigma_{11} = \sigma_{22}$  e  $\sigma_{12} > 0$



# Distribuição normal multivariada

Contornos da Distribuição Normal Bivariada



## Definição (Distribuição normal $p$ -variada padrão)

*Um vetor aleatório  $\mathbf{Z}$  de ordem  $p \times 1$  tem distribuição normal  $p$ -variada padrão se somente se a f.d.p de é dada por*

$$f(\mathbf{z}) = (2\pi)^{-p/2} \exp \left\{ -\frac{1}{2} \mathbf{z}' \mathbf{z} \right\}, \quad \mathbf{z} \in R^p \quad (5)$$

Notação:  $\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I})$

## Proposição (1)

Se  $\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I})$ , então a função geradora de momentos de  $\mathbf{Z}$  é dada por

$$m_{\mathbf{Z}}(\mathbf{t}) = e^{\frac{\mathbf{t}^\top \mathbf{t}}{2}}, \quad \mathbf{t} \in \mathbb{R}^p. \quad (6)$$

**Prova:** Da definição da f.g.m.

$$\begin{aligned} m_{\mathbf{Z}}(\mathbf{t}) &= E(e^{\mathbf{t}^\top \mathbf{Z}}) = \int \cdots \int \frac{1}{(2\pi)^{p/2}} e^{\mathbf{t}^\top \mathbf{z} - \frac{\mathbf{z}^\top \mathbf{z}}{2}} d\mathbf{z} \\ &= e^{\sum_{i=1}^p t_i^2/2} \int \cdots \int \frac{1}{(2\pi)^{p/2}} e^{-\frac{1}{2} \sum_{i=1}^p (z_i - t_i)^2} dz_1, \dots, dz_p \\ &= e^{\frac{\mathbf{t}^\top \mathbf{t}}{2}}. \end{aligned}$$

## Proposição (2)

Considere o vetor aleatório  $\mathbf{Z}$ , tal que,  $\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I})$ . Seja  $\gamma$  um vetor de constantes reais de ordem  $p \times 1$  e  $\gamma_0$  qualquer constante real. Então a variável aleatória,

$$X = \gamma' \mathbf{Z} + \gamma_0$$

tem distribuição normal com média  $\gamma_0$  e variância  $\gamma' \gamma$ .

**Prova:** Como  $X = \gamma' \mathbf{Z} + \gamma_0$  é uma v.a, vamos determinar a f.g.m. Por definição,

$$\begin{aligned} m_X(t) &= E(e^{tX}) = E(e^{t(\gamma' \mathbf{Z} + \gamma_0)}) = e^{t\gamma_0} E(e^{t(\gamma' \mathbf{Z})}) \\ &= \int \cdots \int \frac{1}{(2\pi)^{p/2}} e^{t(\gamma' \mathbf{z}) - \frac{\mathbf{z}^\top \mathbf{z}}{2}} d\mathbf{z} \\ &= e^{t\gamma_0 + \frac{(\gamma' \gamma)t^2}{2}}, \quad t \in R. \end{aligned}$$

## Exemplo

Seja  $Z \sim N_3(\mathbf{0}, I)$ . Determinar a distribuição de  $Y = Z_1 - 2Z_2 + 4Z_3 + 6$ . Neste caso temos que

$$Y = [1, -2, 4] \begin{bmatrix} Z_1 \\ Z_2 \\ Z_3 \end{bmatrix} + 6 = \boldsymbol{\gamma}' \mathbf{Z} + \gamma_0.$$

Do resultado anterior temos que  $Y \sim N(6, 21)$ .

## Exercício

Seja  $Z \sim N_4(\mathbf{0}, I)$ . Determinar a distribuição de  $X = Z_1 + Z_2 + 4Z_3 + Z_4 + 1$ .

## Proposição (3)

Se  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ , com f.d.p. dada em (1) e seja

$$\mathbf{Y} = \Sigma^{-1/2}(\mathbf{X} - \boldsymbol{\mu}), \quad (7)$$

onde  $\Sigma^{-1/2}$  é a matriz raiz quadrada de  $\Sigma^{-1}$ . Então  $Y_1, \dots, Y_p$  são variáveis aleatórias independentes com distribuição normal padrão.

**Prova:** De (7), tem-se que

$$(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) = \mathbf{Y}^\top \mathbf{Y}.$$

Observe em (7),  $\mathbf{x} = \Sigma^{1/2}\mathbf{y} + \boldsymbol{\mu}$ , daí o Jacobiano da transformação é  $|\Sigma|^{1/2}$ . Considerando (1), a f.d.p. é dada por

$$g(\mathbf{y}) = \frac{1}{(2\pi)^{p/2}} e^{-\sum_{i=1}^p y_i^2/2}, \quad y_i \in \mathbb{R}.$$



## Proposição (4)

Se  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ , então a função geradora de momentos de  $\mathbf{X}$  é dada por

$$\phi_{\mathbf{X}}(\mathbf{t}) = e^{\mathbf{t}'\boldsymbol{\mu} + \frac{\mathbf{t}'\Sigma\mathbf{t}}{2}}, \quad \mathbf{t} \in R^p. \quad (8)$$

**Prova:** Considerando o resultado (3),  $\mathbf{X} = \Sigma^{1/2}\mathbf{Y} + \boldsymbol{\mu}$  determinamos que a função geradora de momentos de  $\mathbf{X}$  é dada por

$$\phi_{\mathbf{X}}(\mathbf{t}) = E(e^{\mathbf{t}'\mathbf{X}}) = e^{\mathbf{t}'\boldsymbol{\mu}} E(e^{\mathbf{u}'\mathbf{Y}}),$$

onde

$$\mathbf{u}' = \mathbf{t}'\Sigma^{1/2}.$$

Como os  $Y_i$ 's são independentes  $N_1(0, 1)$  tem-se

$$\begin{aligned} E(e^{\mathbf{u}'\mathbf{y}}) &= \prod_{i=1}^p \phi_{y_i}(u_i) = \prod_{i=1}^p e^{u_i^2/2} = e^{\mathbf{u}'\mathbf{u}/2} \\ &= e^{\mathbf{t}'\boldsymbol{\mu} + \mathbf{t}'\boldsymbol{\Sigma}^{1/2}\boldsymbol{\Sigma}^{1/2}\mathbf{t}/2} \\ &= e^{\mathbf{t}'\boldsymbol{\mu} + \frac{\mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}}{2}}. \end{aligned}$$

$$\begin{aligned} \phi_{\mathbf{X}}(\mathbf{t}) &= e^{\mathbf{t}'\boldsymbol{\mu} + \mathbf{u}'\mathbf{u}/2} = e^{\mathbf{t}'\boldsymbol{\mu} + \mathbf{t}'\boldsymbol{\Sigma}^{1/2}\boldsymbol{\Sigma}^{1/2}\mathbf{t}/2} \\ &= e^{\mathbf{t}'\boldsymbol{\mu} + \frac{\mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}}{2}}. \end{aligned}$$

## Proposição (5)

Se  $\mathbf{X}$  é um vetor aleatório normal multivariado de ordem  $p \times 1$  com vetor médias  $\boldsymbol{\mu}$  e matriz de covariância  $\Sigma$  e seja  $A$  uma matriz de constantes de ordem  $m \times p$  e  $\mathbf{b}$  vetor de constante de ordem  $m \times 1$ , então o vetor aleatório

$$\mathbf{Y} = A\mathbf{X} + \mathbf{b},$$

tem distribuição normal  $m$ -variada com vetor de médias  $A\boldsymbol{\mu} + \mathbf{b}$  e covariância  $A\Sigma A^T$ .

**Prova:** (Exercício)

# Propriedades da distribuição normal multivariada

Se  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ , então:

- 1 Combinações lineares das componentes de  $\mathbf{X}$  são normalmente distribuídos. Ou seja, a v.a.

$$Y = a_1X_1 + a_2X_2 + \dots + a_pX_p = \begin{bmatrix} a_1 & a_2 & \dots & a_p \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix} \mathbf{X} = \mathbf{a}\mathbf{X},$$

terá distribuição  $N_1(\mathbf{a}^\top \boldsymbol{\mu}, \mathbf{a}^\top \Sigma \mathbf{a})$ , onde  $\mathbf{a} = (a_1, \dots, a_p)$ .

- 2 Todo os componentes de  $\mathbf{X}$  tem distribuição normal. Fazendo

$$\begin{bmatrix} 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix} \mathbf{X} = X_1,$$

Assim,  $x_1 \sim N(\mu_1, \sigma_{11})$ .

# Propriedades da distribuição normal multivariada

- 1 Considere a partição  $\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}$  onde  $\mathbf{X}_1$  e  $\mathbf{X}_2$  são vetores aleatórios de ordem  $q \times 1$  e  $(p-q) \times 1$  respectivamente. Sejam as correspondentes partições no vetor de média e covariância, dadas por

$$\boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix}$$

Seja a matriz  $\mathbf{A} = [\mathbf{I}_{q \times q} \mid \mathbf{O}_{(p-q) \times p}]$ , do Resultado (5) tem-se,  $\mathbf{AX} = \mathbf{X}_1 \sim N_q(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})$

- 2 Se os componentes de covariância forem zero entre dois subconjuntos de  $\mathbf{X}$ , implica em dizer que eles são independentemente distribuídos. Esta propriedade só é válida se  $\mathbf{X}$  tiver distribuição normal multivariada.

## Proposição (6)

Se  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  e  $\mathbf{X}_1$  e  $\mathbf{X}_2$  é a partição de  $\mathbf{X}$  de ordem  $q \times 1$  e  $(p - q) \times 1$  respectivamente e suponha que  $\boldsymbol{\mu}$  e  $\boldsymbol{\Sigma}$  são particionados de acordo. Isto é

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix} \sim N_p \left( \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix} \right).$$

Então

- (i) Os vetores aleatórios  $\mathbf{X}_1$  e  $\mathbf{X}_2$  são independentes se e somente se  $\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \boldsymbol{\Sigma}_{12} = \mathbf{0}$
- (ii) A distribuição condicional  $\mathbf{X}_1$  dado  $\mathbf{X}_2 = \mathbf{x}_2$  é

$$N_p \left( \boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21} \right)$$

**Prova:** Considere o vetor aleatório  $\mathbf{X}_1^* = \mathbf{X}_1 + \Sigma_{12}\Sigma_{22}^{-1}\mathbf{X}_2$  e  $\mathbf{X}_2^* = \mathbf{X}_2$ .

$$\mathbf{X}^* = \begin{pmatrix} \mathbf{X}_1^* \\ \mathbf{X}_2^* \end{pmatrix} = \mathbf{A}\mathbf{X}, \quad \mathbf{A} = \begin{pmatrix} \mathbf{I}_p & \Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}_{p \times (p-q)} & \mathbf{I}_{p-q} \end{pmatrix}$$

Pela Proposição 5, o vetor aleatório  $\mathbf{X}^*$  tem distribuição normal. Uma inspeção da matriz de covariância de  $\mathbf{X}^*$  leva que  $\mathbf{X}_1^*$  e  $\mathbf{X}_2^*$  são independentes. Daí

$$\mathbf{X}_1 = \mathbf{X}_1^* - \Sigma_{12}\Sigma_{22}^{-1}\mathbf{X}_2$$

e que a distribuição (em lei) de  $\mathbf{X}_1$  dado  $\mathbf{X}_2 = \mathbf{x}_2$  é

$$\mathcal{L}(\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2) = \mathcal{L}(\mathbf{X}_1^* - \Sigma_{12}\Sigma_{22}^{-1}\mathbf{X}_2 | \mathbf{X}_2 = \mathbf{x}_2) = \mathcal{L}(\mathbf{X}_1^* - \Sigma_{12}\Sigma_{22}^{-1}\mathbf{x}_2 | \mathbf{X}_2 = \mathbf{x}_2)$$

a qual é normal multivariada de dimensão  $q$ .

# Teorema do Limite Central Multivariado

## Teorema

Se  $\mathbf{X}_1, \mathbf{X}_2, \dots$  é uma sequência vetores aleatórios i.i.d, de dimensão  $p$  com  $E[\mathbf{X}] = \boldsymbol{\mu}$  e  $\text{Cov}(\mathbf{X}) = \boldsymbol{\Sigma}$  (positiva definida) então

$$n^{-1/2} \sum_{j=1}^n (\mathbf{X}_j - \boldsymbol{\mu}) \xrightarrow{d} N_p(\mathbf{0}, \boldsymbol{\Sigma}), \quad n \longrightarrow \infty.$$

ou

$$n^{1/2} (\bar{\mathbf{X}} - \boldsymbol{\mu}) \xrightarrow{d} N_p(\mathbf{0}, \boldsymbol{\Sigma}), \quad n \longrightarrow \infty.$$

## Corolário

(Método Delta) Sob as condições do TCL, se  $h(\cdot)$  é uma função  $h: R^p \longrightarrow R$ , então

$$n^{1/2} (h(\bar{\mathbf{X}}) - h(\boldsymbol{\mu})) \xrightarrow{d} N_p(\mathbf{0}, (\Delta h(\boldsymbol{\mu}))^\top \boldsymbol{\Sigma} \Delta h(\boldsymbol{\mu})), \quad n \longrightarrow \infty.$$

onde  $\Delta h(\mathbf{x})$  denota a gradiente de  $h$  em  $\mathbf{x}$ .



# Formas quadráticas em vetores aleatórios normais

Seja  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ . Uma forma quadrática em  $\mathbf{X}$  é uma variável aleatória da forma

$$Y = \mathbf{X}^\top \mathbf{A} \mathbf{X} = \sum_{i=1}^p \sum_{j=1}^p X_i a_{ij} X_j$$

onde  $\mathbf{A} = \{a_{ij}\}$  é uma matriz simétrica de ordem  $p \times p$  e  $X_j$  é o  $j$ -ésimo elemento de  $\mathbf{X}$ .

Estamos interessados na distribuição das formas quadráticas e nas condições em que duas formas quadráticas são independentes.

## Exemplo

Se  $\mathbf{X} \sim N_p(\mathbf{0}, \mathbf{I}_p)$  e  $\mathbf{A} = \mathbf{I}_p$ , Então

$$Y = \mathbf{X}^\top \mathbf{A} \mathbf{X} = \mathbf{X}^\top \mathbf{X} = \sum_{i=1}^p X_i^2 \sim \chi_{(p)}^2$$

## Exemplo

Se  $\mathbf{X} \sim N_p(\mathbf{0}, \mathbf{I}_p)$  e  $\mathbf{A} = \mathbf{I}_p$ , Então

$$Y = \mathbf{X}^\top \mathbf{A} \mathbf{X} = \mathbf{X}^\top \mathbf{X} = \sum_{i=1}^p X_i^2 \sim \chi^2_{(p)}$$

## Teorema

Se  $\mathbf{X} \sim N_p(0, \sigma^2 \mathbf{I}_p)$  e  $\mathbf{A}$  é uma matriz simétrica de ordem  $p \times p$ .  
Então

$$\frac{\mathbf{X}^\top \mathbf{A} \mathbf{X}}{\sigma^2} \sim \chi^2_{(m)}$$

se e somente  $\mathbf{A}$  idempotente de posto  $m < p$ .

## Corolário

Se  $\mathbf{X} \sim N_p(\mathbf{0}, \Sigma)$  e  $\mathbf{A}$  é uma matriz simétrica de ordem  $p \times p$ .  
Então

$$\mathbf{X}^\top \mathbf{A} \mathbf{X} \sim \chi^2_{(m)}$$

se e somente  $\mathbf{A}\Sigma$  idempotente (ou  $\Sigma\mathbf{A}$  idempotente) de posto  $m < p$ .

## Exemplo

Se  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ , então  $(\mathbf{X} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{X} - \boldsymbol{\mu}) \sim \chi^2_{(p)}$

## Teorema

Seja  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ ,  $\mathbf{A}$  uma matriz simétrica de posto  $m$ . Então

$$\mathbf{X}^\top \mathbf{A} \mathbf{X} \sim \chi_{(m)}^2(\lambda)$$

se somente se  $\mathbf{A}\boldsymbol{\Sigma}$  é idempotente, sendo  $\lambda = \frac{1}{2}\boldsymbol{\mu}^\top \mathbf{A}\boldsymbol{\mu}$ , o parâmetro de não centralidade)

## Exemplo

Se  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , então  $(\mathbf{X} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{X} - \boldsymbol{\mu}) \sim \chi_{(p)}^2(0)$

pois  $\lambda = \frac{1}{2}(E(\mathbf{X} - \boldsymbol{\mu}))^\top \boldsymbol{\Sigma}^{-1}E(\mathbf{X} - \boldsymbol{\mu}) = 0$

# Formas quadráticas em vetores aleatórios normais

## Teorema

Seja  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$   $\mathbf{A}$  uma matriz simétrica de ordem  $p \times p$  e  $\mathbf{B}$  uma matriz de ordem  $k \times p$ . Se  $\mathbf{B}\boldsymbol{\Sigma}\mathbf{A} = \mathbf{0}$  então  $\mathbf{B}\mathbf{X}$  e  $\mathbf{X}^\top \mathbf{A}\mathbf{X}$  são independentes.

## Exemplo

Seja  $X_1, \dots, X_n$  é uma amostra aleatória de  $N(\mu, \sigma^2)$  A média amostral  $\bar{X}_n$  e a variância amostral  $S_n^2 = (n-1)^{-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$  são independentes.

Note que :  $\mathbf{X} \sim N_n(\mu \mathbf{1}_n, \boldsymbol{\Sigma} = \sigma^2 I_n)$ ,  $\bar{X}_n = (\frac{1}{n}, \dots, \frac{1}{n}) \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix} = \frac{1}{n} \mathbf{1}^\top \mathbf{X} =$

$\mathbf{B}\mathbf{X}$  e  $(n-1)^{-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = (n-1)^{-1} \mathbf{X}^\top (I_n - \frac{1}{n} \mathbf{1} \mathbf{1}^\top) \mathbf{X} = \mathbf{X}^\top \mathbf{A}\mathbf{X}$ . Daí tem-se  $\mathbf{B}\boldsymbol{\Sigma}\mathbf{A} = \mathbf{0}$

# Formas quadráticas em vetores aleatórios normais

## Teorema

Seja  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ . Suponha que  $\mathbf{A}$  e  $\mathbf{B}$  são matrizes simétricas de ordem  $p \times p$ . Se  $\mathbf{B}\boldsymbol{\Sigma}\mathbf{A} = \mathbf{0}$  então  $\mathbf{X}^\top \mathbf{B} \mathbf{X}$  e  $\mathbf{X}^\top \mathbf{A} \mathbf{X}$  são independentes.

## Exercício

Considere o modelo de regressão múltipla

$$X_i = \beta_0 + \sum_{j=1}^p z_{ij}\beta_j + \varepsilon_i, \quad i = 1, \dots, n$$

com  $\varepsilon_i \stackrel{i.i.d}{\sim} N(0, \sigma^2)$ . Mostre que a soma de quadrados do residual e soma de quadrados da regressão são independentes.

## Teorema

Se  $\mathbf{A}$  é uma matriz de ordem  $p \times p$  e  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ . Então

- $E[\mathbf{X}^\top \mathbf{A} \mathbf{X}] = \text{tr}(\mathbf{A} \boldsymbol{\Sigma}) + \boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\mu}$
- $\text{Var}[\mathbf{X}^\top \mathbf{A} \mathbf{X}] = \text{tr}(\mathbf{A} \boldsymbol{\Sigma} \mathbf{A} \boldsymbol{\Sigma}) + 4 \boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\Sigma} \boldsymbol{\mu}$

**Prova** Como  $\boldsymbol{\Sigma} = E[\mathbf{X} \mathbf{X}^\top] - \boldsymbol{\mu} \boldsymbol{\mu}^\top$ , tem-se  $E[\mathbf{X} \mathbf{X}^\top] = \boldsymbol{\Sigma} + \boldsymbol{\mu} \boldsymbol{\mu}^\top$ .

$$\begin{aligned} E[\mathbf{X}^\top \mathbf{A} \mathbf{X}] &= E[\text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X})] = E[\text{tr}(\mathbf{A} \mathbf{X} \mathbf{X}^\top)] = \text{tr}(E[\mathbf{A} \mathbf{X} \mathbf{X}^\top]) \\ &= \text{tr}(\mathbf{A} E[\mathbf{X} \mathbf{X}^\top]) = \text{tr}(\mathbf{A} (\boldsymbol{\Sigma} + \boldsymbol{\mu} \boldsymbol{\mu}^\top)) \\ &= \text{tr}(\mathbf{A} \boldsymbol{\Sigma} + \mathbf{A} \boldsymbol{\mu} \boldsymbol{\mu}^\top) = \text{tr}(\mathbf{A} \boldsymbol{\Sigma}) + \text{tr}(\mathbf{A} \boldsymbol{\mu} \boldsymbol{\mu}^\top) \\ &= \text{tr}(\mathbf{A} \boldsymbol{\Sigma}) + \boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\mu}. \end{aligned}$$