

Inferência a Respeito dos Parâmetros da Distribuição Normal Multivariada

Vicente G. Cancho
garibay@icmc.usp.br

Definição

Dizemos que um vetor aleatório \mathbf{X} de ordem $(p \times 1)$ tem distribuição normal multivariada (ou p -variada) com vetor de médias $\boldsymbol{\mu}$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$ de ordem $p \times p$, se sua função de densidade conjunta é dada por

$$f(\mathbf{x}) = ((2\pi)^p |\boldsymbol{\Sigma}|)^{-1/2} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}, \quad \mathbf{x} \in R^p. \quad (1)$$

$$\text{onde } \boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2p} \\ \vdots & \vdots & \dots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_{pp} \end{pmatrix}.$$

Notação: $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

Propriedades da distribuição normal multivariada

Se $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e \mathbf{X}_1 e \mathbf{X}_2 é a partição de \mathbf{X} de ordem $q \times 1$ e $(p-q) \times 1$ respectivamente e suponha que $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$ são particionados de acordo. Isto é

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix} \sim N_p \left(\begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix} \right).$$

Então

- (i) $X_j \sim N(\mu_j, \sigma_{jj})$, $j = 1, \dots, p$.
- (ii) $\mathbf{Y} = \mathbf{A}\mathbf{X} \sim N_q(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)$
- (iii) A distribuição condicional \mathbf{X}_1 dado $\mathbf{X}_2 = \mathbf{x}_2$ é

$$N_p(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21})$$

- (iv) $(\mathbf{X} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{X} - \boldsymbol{\mu}) \sim \chi^2_{(p)}$

Suponha que $\mathbf{X}_i = (X_{i1}, \dots, X_{ip})^\top$ é i -ésima amostra de uma população normal multivariada com vetor de médias μ e matriz de variância-covariância Σ , ou seja $\mathbf{X}_i \stackrel{i.i.d}{\sim} N_p(\mu, \Sigma)$.

A função de verossimilhança de μ e Σ dada a amostra observada é dada por

$$L(\mu, \Sigma) = \prod_{i=1}^n ((2\pi)^p |\Sigma|)^{-1/2} \exp \left\{ -\frac{1}{2} (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}$$

A função log-verossimilhança

$$\ell((\mu, \Sigma)) = -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log(|\Sigma|) - \sum_{i=1}^n \frac{1}{2} (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu)$$

O EMV do vetor médias é o valor de μ que minimiza

$$\sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) = \sum_{i=1}^n \mathbf{x}_i^\top \Sigma^{-1} \mathbf{x}_i - 2n\bar{\mathbf{x}}^\top \Sigma^{-1} \mu + n\mu^\top \Sigma^{-1} \mu$$

onde $\bar{\mathbf{x}} = n^{-1} \sum_{i=1}^n \mathbf{x}_i$ é o vetor de medias amostrais.

Tomando a derivada em relação a μ , obtém-se

$$\frac{\partial \ell((\mu, \Sigma))}{\partial \mu} = -2n\Sigma^{-1}\bar{\mathbf{x}} + 2n\Sigma^{-1}\mu \iff \hat{\mu} = \bar{\mathbf{x}}.$$

vetor de medias amostrais $\bar{\mathbf{x}}$ é o EMV do vetor de médias populacional μ

Estimador de máxima verossimilhança da matriz de covariâncias

O EMV da matriz de covariância é o valor de Σ que minimiza

$$-n \log(|\Sigma^{-1}|) + \sum_{i=1}^n \text{tr}(\Sigma^{-1}(\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top)$$

$\hat{\boldsymbol{\mu}} = \bar{\mathbf{x}}$ o vetor de medias amostrais.

Tomando a derivada em relação ao Σ^{-1} obtém-se

$$\frac{\partial \ell((\boldsymbol{\mu}, \Sigma))}{\partial \Sigma^{-1}} = -n\Sigma + \sum_{i=1}^n (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top$$

a matriz de covariâncias $\hat{\Sigma} = n^{-1} \sum_{i=1}^n (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top$ é o EMV de Σ .

Distribuição Amostral multivariada: $\bar{\mathbf{X}}$ e \mathbf{S}

Suponha que $\mathbf{X}_1, \dots, \mathbf{X}_n > n$ é uma a.a. de uma população $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.
Sejam

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}})(\mathbf{x}_i - \bar{\mathbf{X}})^\top$$

o vetor de médias e a matriz de covariâncias amostrais.

Teorema (3)

$\bar{\mathbf{X}}$ e $\bar{\mathbf{S}}$ são independentes com

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}/n)$$

$$(n-1)\mathbf{S} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}})(\mathbf{x}_i - \bar{\mathbf{X}})^\top \sim W_p(n-1, \boldsymbol{\Sigma})$$

Corolário (2)

A estatística T^2 de Hotelling para uma amostra multivariada é

$$T^2 = n(\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\mathbf{X} - \boldsymbol{\mu})$$

e tem-se

$$\frac{n-p}{p} \frac{n}{n-1} (\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\mathbf{X} - \boldsymbol{\mu}) \sim F_{p, n-p}$$

Dado um modelo estatístico, com função distribuição P_{θ} , com $\theta \in \Theta \subset R^p$, tem-se interesse em testar as seguintes hipóteses:

$$H_0 : \theta \in \Theta_0, \text{ vs } H_1 : \theta \in \Theta_1$$

tal que $\Theta_0 \cup \Theta_1 = \Theta$ e $\Theta_0 \cap \Theta_1 = \emptyset$. A estatística da razão de verossimilhança, ou às vezes chamada de estatística de Wilks, é então

$$W = -2 \log \left(\frac{\sup_{\theta \in \Theta_0} L(\theta)}{\sup_{\theta \in \Theta} L(\theta)} \right)$$

A hipótese nula é rejeitada se o valor observado de W for grande. Em alguns casos, a distribuição exata de W em H_0 pode ser avaliada. Em outros casos, o teorema de Wilks afirma que para n grande,

$$W \xrightarrow{d} \chi^2_{\nu},$$

onde ν é o número de parâmetros livres em H_1 , mas não em H_0 .

Suponha que tem-se interesse em testar hipóteses sobre os parâmetros da distribuição normal multivariada, baseado uma amostra aleatória, $\mathbf{X}_1, \dots, \mathbf{X}_n$, de uma população normal com vetor de médias $\boldsymbol{\mu}$ e matriz de variâncias $\boldsymbol{\Sigma}$.

1. $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$ vs $H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$ quando $\boldsymbol{\Sigma}$ é conhecido

Neste caso, sabemos a distribuição exata da estatística da razão de verossimilhança

$$W = n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \boldsymbol{\Sigma}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0) \sim \chi^2_{(p)}$$

sob H_0 .

Note que

$$-2 \log L(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = n \log(2\pi\boldsymbol{\Sigma}) + n \text{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S}) + n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu})$$

Vimos que o EMV irrestrito de $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$ é $\hat{\boldsymbol{\mu}} = \bar{\mathbf{X}}$ e

$$-2 \log(\sup_{\boldsymbol{\theta} \in \Theta} L(\boldsymbol{\mu}, \boldsymbol{\Sigma})) = n \log(2\pi\boldsymbol{\Sigma}) + n \text{tr}(\boldsymbol{\Sigma}^{-1} \mathbf{S})$$

O EMV de $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$ sob H_0 é $\tilde{\boldsymbol{\mu}} = \boldsymbol{\mu}_0$ e

$$-2 \log(\sup_{\boldsymbol{\theta} \in \Theta_0} L(\boldsymbol{\mu}, \boldsymbol{\Sigma})) = n \log(2\pi\boldsymbol{\Sigma}) + n \text{tr}(\boldsymbol{\Sigma}^{-1} \mathbf{S}) + n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}_0)$$

Dai tem-se

$$W = n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}_0)$$

que sob H_0 tem distribuição qui-quadrado com p graus de liberdade.

2. $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$ quando Σ é desconhecido

- Sabemos que, a EMV de μ e Σ irrestrito são $\hat{\mu}$ e $\hat{\Sigma} = n^{-1} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top = S_0 = \frac{n-1}{n} \mathbf{S}$.
- O EMV de μ e Σ sob H_0 são $\hat{\mu} = \mu_0$ e

$$\hat{\Sigma}_0 = n^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu_0)(\mathbf{x}_i - \mu_0)^\top = S_0 + \delta \delta_0^\top$$

onde $\delta = \sqrt{n}(\bar{\mathbf{x}} - \mu_0)$. A estatística da razão de verossimilhança é então

$$W = n \log |S_0 + \delta \delta_0^\top| - n \log(S_0)$$

- Note que W é uma função crescente monótona de

$$\delta^\top \mathbf{S}^{-1} \delta = n(\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu_0)$$

que é a estatística T^2 de Hotelling.

3. $H_0 : \Sigma = \Sigma_0$ vs $H_1 : \Sigma \neq \Sigma_0$, μ desconhecido

Temos a estatística da razão de verossimilhança

$$W = -n \log (|\Sigma_0^{-1} \mathbf{S}_0|) - np + \text{tr}(\Sigma_0^{-1} \mathbf{S}_0)$$

Esse é o caso em que a distribuição exata de W é difícil de determinar. Para n grande, a distribuição de W é tem distribuição qui-quadrado com $p(p+1)/2$ graus de liberdade

Exemplo

Com a finalidade de verificar se o rendimento médio (RM), nas disciplinas de matemática, ciências, inglês e espanhol, dos alunos do último ano do ensino médio são as mesmas aos alunos de anos anteriores, foram escolhidos aleatoriamente 10 alunos cujos rendimentos resultaram

Aluno	Mat	Ciência	Inglês	Espanhol
1	81	89	73	74
2	73	79	73	74
3	61	86	81	81
4	55	70	76	73
5	61	71	61	66
6	52	70	56	58
7	56	74	56	56
8	65	87	73	69
9	54	76	69	72
10	48	71	62	63

A nota média em cada uma das disciplinas em anos anteriores foi 60 pontos. Isso mudou? Use $\alpha = 0,05$.

- X_1 : RM em Matemática
- X_2 : RM em Ciências
- X_3 : RM em Inglês,
- X_4 : RM em Espanhol.

Se $E(X_j) = \mu_j$ representa a RM média de todos alunos na disciplina j .
Então as hipóteses de interesse é

$$H_0 := \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \mu_4 \end{pmatrix} = \begin{pmatrix} 60 \\ 60 \\ 60 \\ 60 \end{pmatrix} = \boldsymbol{\mu}_0 \text{ vs } H_1 := \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \mu_4 \end{pmatrix} \neq \begin{pmatrix} 60 \\ 60 \\ 60 \\ 60 \end{pmatrix} = \boldsymbol{\mu}_0$$

Testes de hipóteses para vetor de médias

Seja $\mathbf{X}_1, \dots, \mathbf{X}_n$ uma amostra aleatória de uma população com vetor de médias $\boldsymbol{\mu}$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$. Sejam $\bar{\mathbf{X}}$ e \mathbf{S} o vetor de médias amostrais e a matriz de variâncias e covariâncias amostrais.

Hipóteses de interesse: $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$ vs $H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$.

Supondo que a amostra vem de uma população $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, tem-se que sob H_0

$$T^2 = n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0) \sim \frac{(n-1)p}{n-p} F_{p, n-p}$$

Assim, rejeitamos H_0 a um nível de significância α se

$$T_{obs}^2 = n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}_0) > \frac{(n-1)p}{n-p} F_{p, n-p}^{-1}(1 - \alpha)$$

em que $F_{p, n-p}^{-1}(1 - \alpha)$ é o quantil $1 - \alpha$ da distribuição $F_{p, n-p}$.

Testes de hipóteses para vetor de médias: Exemplo

Dos dados do Exemplo tem-se

$$\bar{\mathbf{x}} = \begin{pmatrix} 60.6 \\ 77.3 \\ 68.0 \\ 68.6 \end{pmatrix} \quad S = \begin{pmatrix} 102.04 & 56.69 & 41.22 & 39.49 \\ 56.69 & 56.46 & 42.00 & 35.36 \\ 41.22 & 42.00 & 75.78 & 65.11 \\ 39.49 & 35.36 & 65.11 & 61.38 \end{pmatrix}$$

A estatística observada

$$T_{obs}^2 = n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)^\top S^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}_0) = 151,1352$$

Para um nível de significância de 5% tem-se

$$\frac{(n-1)p}{n-p} F_{p, n-p}^{-1}(1-\alpha) = \frac{9 \times 4}{10-4} F_{4,6}^{-1}(0,95) = 27,18 < 151,1352$$

Rejeita-se H_0 , ao nível de significância de 5%.

Testes de hipóteses para vetor de médias: Exemplo

Equivalentemente

$$\frac{n-p}{(n-1)p} T^2 = \frac{6}{9 \times 4} 151,1352 = 25,1892 > F_{4,6}^{-1}(0,95) = 4,534$$

```
> library(ICSNP)
> HotellingsT2(x, mu = c(60,60,60,60), test = "f")
Hotelling's one sample T2-test

data:  x
T.2 = 25.189, df1 = 4, df2 = 6, p-value = 0.0006802
alternative hypothesis: true location is not equal to c(60,60,60,60)
```

Testes de hipóteses para vetor de médias: Exemplo

Equivalentemente

$$\frac{n-p}{(n-1)p} T^2 = \frac{6}{9 \times 4} 151,1352 = 25,1892 > F_{4,6}^{-1}(0,95) = 4,534$$

```
> library(ICSNP)
> HotellingsT2(x, mu = c(60,60,60,60), test = "f")
Hotelling's one sample T2-test

data:  x
T.2 = 25.189, df1 = 4, df2 = 6, p-value = 0.0006802
alternative hypothesis: true location is not equal to c(60,60,60,60)
```

Para grandes amostras

```
> HotellingsT2(x, mu = c(60,60,60,60), test = "chi")

Hotelling's one sample T2-test
data:  x
T.2 = 151.14, df = 4, p-value < 2.2e-16
alternative hypothesis: true location is not equal to c(60,60,60,60)
```

Definição

A região de confiança de $100(1 - \alpha)\%$ determinado pela amostra aleatória $\mathbf{X} = (\mathbf{X}_1, \dots, \mathbf{X}_n)$ é denotado por $\mathcal{R}_{\mathbf{X}}$ é

$$P(\mathcal{R}_{\mathbf{X}} \text{ contém o verdadeiro valor } \theta) = 1 - \alpha.$$

onde P é a distribuição de probabilidade de \mathbf{X} e $\theta \in \Theta \subset R^2$.

Das propriedades do EMV dos parâmetros da distribuição normal multivariada tem-se

$$\frac{n(n-p)}{(n-1)p} (\bar{\mathbf{X}} - \boldsymbol{\mu})^\top S^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim F_{p, n-p}$$

é uma quantidade pivotal.

Daí

$$P \left(n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top S^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{n-p} F_{p, n-p}^{-1}(1-\alpha) \right) = 1 - \alpha,$$

onde $F_{p, n-p}^{-1}(1-\alpha)$ é o quantil $1-\alpha$ da distribuição F com p e $n-p$ graus de liberdade.

Temos que

$$\mathcal{A} = \left\{ \boldsymbol{\mu} \in R^p : n(\bar{\mathbf{x}} - \boldsymbol{\mu})^\top S^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{n-p} F_{p, n-p}^{-1}(1-\alpha) \right\}$$

é a **região com $100(1-\alpha)\%$ de confiança** para $\boldsymbol{\mu}$.

Se $\boldsymbol{\mu}_0 \in \mathcal{A}$, não rejeitamos $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$; caso contrário, rejeitamos H_0 .

Região de Confiança

- Para $p > 4$ não se pode fazer gráficos da região de confiança para μ .
- Não entanto, pode-se calcular os eixos da elipsoide de confiança e seus tamanhos relativos, os quais são determinados pelos autovalores λ_i e os autovetores \mathbf{e}_i de \mathbf{S} .
- Os tamanhos dos semi-eixos de

$$n(\bar{\mathbf{x}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}) \leq c^2 = \frac{(n-1)p}{n-p} F_{p, n-p}^{-1}(1-\alpha)$$

são determinados por

$$\frac{\sqrt{\lambda_i}c}{\sqrt{n}} = \sqrt{\lambda_i} \sqrt{\frac{(n-1)p}{(n-p)n} F_{p, n-p}^{-1}(1-\alpha)}$$

- Começando do centro, determinado por $\bar{\mathbf{X}}u$ os eixos de elipsóide são:

$$\sqrt{\lambda_i} \sqrt{\frac{(n-1)p}{(n-p)n} F_{p, n-p}^{-1}(1-\alpha)} \mathbf{e}_i$$

Região de Confiança: Exemplo

Obter uma região de 95% de confiança para μ e verifique se o ponto $\mu_0 = (13, 4)^\top$ pertence a mesma. Considere a seguinte informação/

$$\bar{x} = \begin{pmatrix} 10 \\ 2 \end{pmatrix}, S = \begin{pmatrix} 1 & -0,5 \\ -0,5 & 1 \end{pmatrix}, S^{-1} = \frac{1}{3} \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix} \text{ e } n = 2.$$

Os autovalores e autovetores de S , são:

$$\lambda_1 = 1.5 \mathbf{e}_1 = (-0.7071068, -0.7071068)^\top$$

$$\lambda_2 = 0.5 \mathbf{e}_2 = (0.7071068, -0.7071068)^\top$$

Região de Confiança: Exemplo

A elipse de 95% confiança para μ consiste de todos os valores (μ_1, μ_2) que satisfazem

$$(10 - \mu_1 \quad 3 - \mu_2) \frac{1}{3} \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix} \begin{pmatrix} 10 - \mu_1 \\ 3 - \mu_2 \end{pmatrix} \leq \frac{2(2)}{1} \times 199,5.$$


ou

$$4(10 - \mu_1) + 4(10 - \mu_1)(3 - \mu_2) + 4(3 - \mu_2)^2 \leq 708$$

Para verificar se o ponto $\mu_0^\top = (13, 4)$ pertence a elipse, calcula-se

$$4(10 - 13)^2 + 4(10 - 13)(3 - 4) + 4(3 - 4)^2 = 52 \leq 708$$

Região de Confiança: Exemplo



Intervalo de confiança simultânea

- Suponha $\mathbf{X} = (\mathbf{X}_1, \dots, \mathbf{X}_n)$ é uma amostra aleatória de $N_p(\boldsymbol{\mu}, \Sigma)$ e seja

$$Z_j = a_1 X_{j1} + \dots + a_p X_{jp} = \mathbf{a} \mathbf{X}_j, \quad j = 1, \dots, n$$

ou

- a média e variância amostral dos valores observados z_1, \dots, z_n são respectivamente

$$\bar{z} = a_1 \bar{X}_1 + \dots + a_p \bar{X}_p = \mathbf{a}^\top \bar{\mathbf{X}} \text{ e } s_z^2 = \mathbf{a}^\top S \mathbf{a}$$

- Pode-se mostrar que

$$T = \frac{\bar{Z} - \mu_Z}{s_z / \sqrt{n}} = \frac{\sqrt{n}(\mathbf{a}^\top \bar{\mathbf{X}} - \mathbf{a}^\top \boldsymbol{\mu})}{\sqrt{\mathbf{a}^\top S \mathbf{a}}} \sim t(n-1)$$

Intervalo de confiança simultânea

Um intervalo de $100(1-\alpha)\%$ para $\mathbf{a}^\top \boldsymbol{\mu}$ baseada na distribuição t-Student é dado por

$$\left(\mathbf{a}^\top \bar{\mathbf{X}} - \frac{\sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}}}{\sqrt{n}} F_{T_{(n-1)}}^{-1}(1 - \alpha/2), \mathbf{a}^\top \bar{\mathbf{X}} + \frac{\sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}}}{\sqrt{n}} F_{T_{(n-1)}}^{-1}(1 - \alpha/2) \right) \quad (2)$$

onde $F_{T_{(n-1)}}^{-1}(1 - \alpha/2)$ é o quantile $1 - \alpha/2$ da distribuição t-Student.

O intervalo pode ser interpretado como intervalos sobre componentes do vetor de médias. Por exemplo, fazendo-se 1 na i -ésima posição e zero as outras posições de \mathbf{a}^\top , então (2) dá o intervalo de confiança para μ_i , $i = 1, \dots, p$

Intervalo de confiança simultânea

Não entanto o coeficiente de confiança para todos os intervalos tomados simultaneamente não é $1 - \alpha$. Para corrigir esta imperfeição demonstrase (Johnson e Wichern, 1988) que para garantir o coeficiente nominal de confiança simultâneo de $1 - \alpha$. para a cobertura dos valores paramétricos é necessário recorrer à distribuição T^2 de Hotelling. Este resultado está apresentado a seguir

$$\left(\mathbf{a}^\top \bar{\mathbf{X}} - \sqrt{\frac{(n-1)p}{(n-p)n} (\mathbf{a}^\top \mathbf{S} \mathbf{a}) q_f}, \mathbf{a}^\top \bar{\mathbf{X}} + \sqrt{\frac{(n-1)p}{(n-p)n} (\mathbf{a}^\top \mathbf{S} \mathbf{a}) q_f} \right)$$

onde $q_f = F_{F(p, n-p)}^{-1}(1 - \alpha/2)$ é quantil $1 - \alpha/2$ da distribuição F com p e n-p graus de liberdade.

Esses intervalos são chamados de intervalos de T^2 -Hotelling

Intervalo de confiança simultânea

Note que sucessivas escolhas de $\mathbf{a}_1^\top = (1, 0, \dots, 0)$, $\mathbf{a}_2^\top = (1, 0, \dots, 0), \dots, \mathbf{a}_p^\top = (0, 0, \dots, 1)$

$$\begin{aligned} & \left(\bar{X}_1 - \sqrt{\frac{(n-1)p}{(n-p)}} q_f \sqrt{\frac{s_{11}}{n}}, \bar{X}_1 + \sqrt{\frac{(n-1)p}{(n-p)}} q_f \sqrt{\frac{s_{11}}{n}} \right) \\ & \left(\bar{X}_2 - \sqrt{\frac{(n-1)p}{(n-p)}} q_f \sqrt{\frac{s_{22}}{n}}, \bar{X}_2 + \sqrt{\frac{(n-1)p}{(n-p)}} q_f \sqrt{\frac{s_{22}}{n}} \right) \\ & \vdots \\ & \left(\bar{X}_p - \sqrt{\frac{(n-1)p}{(n-p)}} q_f \sqrt{\frac{s_{pp}^2}{n}}, \bar{X}_p + \sqrt{\frac{(n-1)p}{(n-p)}} q_f \sqrt{\frac{s_{pp}}{n}} \right) \end{aligned}$$

vai conter todos simultaneamente com probabilidade $1 - \alpha$

Intervalo de confiança simultânea

Uma escolha cuidadosa de \mathbf{a}^\top tal como $\mathbf{a}^\top = (1, -1, 0, \dots, 0)$ para os intervalos- T^2 nos permite testar hipóteses especiais

$$\bar{X}_1 - \bar{X}_2 \mp \sqrt{\frac{(n-1)p}{(n-p)} q_f} \sqrt{\frac{s_{11} + s_{22} + 2s_{12}}{n}}$$

Exemplo

Considere os dados a continuação e contrua um intervalo de 90% de confiança para vetor de médias de X_1 e X_2 .

x_1 : 1,43 1,62 2,46 2,48 2,97 4,03 4,47 5,76 6,61 6,68 6,79 7,46 7,88 8,92 9,42

x_2 : -0,69 -5,00 -1,13 -5,20 -6,39 2,87 -7,88 -3,97 2,32 -3,24 -3,56 1,61 -1,87 -6,60 -7,74

Intervalo de confiança simultânea: Exemplo

Dos dados tem-se $n = 15$ e $p = 2$

$$\bar{\mathbf{x}} = \begin{pmatrix} 5,26 \\ -3,09 \end{pmatrix}, S = \begin{pmatrix} 7,12 & -0,72 \\ -0,72 & 12,43 \end{pmatrix} \text{ e } S^{-1} = \begin{pmatrix} 0,1412 & 0,0082 \\ 0,0082 & 0,0809 \end{pmatrix}$$

e

$$q_f = \frac{(n-1)p}{n-p} F_{F(p,n-p)}^{-1}(0,95) = 5,95$$

Se $\mathbf{a}^\top = (1, 0)$ tem-se: $\bar{X}_1 \mp \sqrt{\frac{(n-1)p}{(n-p)}} q_f \sqrt{\frac{s_{11}}{n}}$

$$5,26 \mp \sqrt{5,95} \sqrt{\frac{7,12}{15}}$$

Dai tem-se um intervalo de 90% de confiança para μ_1

$$(3,579; 9,941)$$

Similarmente, um intervalo de 90% de confiança para μ_2

$$(-5,31; -0,87)$$

Intervalo de confiança simultânea: Exemplo

O intervalo de $100(1-\alpha)\%$ de confiança para $\mu_1 - \mu_2$ é dada por

$$\bar{X}_1 - \bar{X}_2 \mp \sqrt{\frac{(n-1)p}{(n-p)} q_f} \sqrt{\frac{s_{11} + s_{22} - 2s_{12}}{n}}$$


Para $1 - \alpha = 0,95$ tem-se

$$5,26 - (-3,09) \mp \sqrt{5,95} \sqrt{\frac{7,12 + 12,42 - 2(9,72)}{15}} = 8,35 \mp 2,885$$

O intervalo de 90% de confiança para $\mu_1 - \mu_2$ é dada por

$$(5,465; 11,235)$$

Intervalo de confiança simultânea: Exemplo



Note-se que as projeções da elipse para os eixos fazem os intervalos de confiança simultâneos

Intervalo de confiança simultânea: Exemplo

O intervalo univariado de $100(1-\alpha)\%$ de confiança para μ_1 é dado por

$$\left(\bar{x}_1 - F_{T(n-1)}^{-1} \sqrt{\frac{s_{11}}{n}}, \bar{x}_1 + F_{T(n-1)}^{-1} \sqrt{\frac{s_{11}}{n}} \right)$$


O intervalo univariado de 90% de confiança para μ_1 é dado por

$$\left(5,26 - 1,76 \sqrt{\frac{7,12}{15}}, 5,26 + 1,76 \sqrt{\frac{7,12}{15}} \right) = 5,26 \mp 1,213 = (4,047, 6,473)$$

Similarmente, O intervalo univariado de 90% de confiança para μ_3 é dado por

$$\begin{aligned} \left(-3,09 - 1,76 \sqrt{\frac{12,43}{15}}, -3,09 + 1,76 \sqrt{\frac{12,43}{15}} \right) &= -3,09 \mp 1,603 \\ &= (-4,69, -1,497) \end{aligned}$$

Intervalo de confiança simultânea: Exemplo



Note que nos IC univariados os comprimentos são mais curtos aos que consideram a correlação de X_1 e X_2

Intervalo de confiança simultânea

Método de Bonferroni

- Muitas vezes um pequeno numero de intervalos de confiança é requerido.
- Nesse caso pode-se ter uma melhor opção do que as comparações simultâneas.
- Intervalos de confiança mais curto (mais curtos) do que intervalo simultâneo de T^2 .
- Essa alternativa de intervalo é conhecido por método de Bonferroni

$$\left(\bar{X}_j - F_{T_{(n-1)}}^{-1} \left(1 - \frac{\alpha}{2p} \right) \sqrt{\frac{s_{jj}}{n}}, \bar{X}_j + F_{T_{(n-1)}}^{-1} \left(1 - \frac{\alpha}{2p} \right) \sqrt{\frac{s_{jj}}{n}} \right), j = 1, \dots, p$$

Intervalo de confiança simultânea: Exemplo

Para os dados do exemplo anterior obtenha os IC de Bonferroni

$$\left(\bar{X}_1 - F_{T(n-1)}^{-1}\left(1 - \frac{\alpha}{2p}\right) \sqrt{\frac{s_{11}}{n}}, \bar{X}_1 + F_{T(n-1)}^{-1}\left(1 - \frac{\alpha}{2p}\right) \sqrt{\frac{s_{11}}{n}} \right),$$

$$(5,26 - 2,145 \sqrt{\frac{7,12}{15}}, 5,26 + 2,145 \sqrt{\frac{7,12}{15}}) = (5,26 - 1,478; 5,26 + 1,478)$$


Um Intervalo de 90% de confiança para μ_1 é: (3,782 ; 6,782).

Similarmente, um IC para μ_2 é

$$\left(-3,09 - 2,145 \sqrt{\frac{12,43}{15}}; -3,09 + 2,145 \sqrt{\frac{12,43}{15}} \right) = -3,09 \mp 1,953;$$

Um Intervalo de 90% de confiança para μ_2 é: (-5,043 , -1,137).

Intervalo de confiança simultâneo: Exemplo



Inferência para amostras grandes ao respeito do vetor de uma média populacional

Seja $\mathbf{X}_1, \dots, \mathbf{X}_n$ uma amostra aleatória de uma população com vetor de médias $\boldsymbol{\mu}$ e matriz variância covariância $\boldsymbol{\Sigma}$ ($\boldsymbol{\Sigma}$ é definida positiva).

$$T^2 = n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \approx \chi^2_{(p)}$$

- \approx significa aproximadamente
- $P\left(n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \leq \chi^2_{(p)}(\alpha)\right) \approx 1 - \alpha$
- Quando $n \longrightarrow \infty$

$$\frac{(n-1)p}{n-p} F_{p, n-p} \longrightarrow \chi^2_{(p)}.$$

Inferência para amostras grandes ao respeito do vetor de uma média

Para $n - p$ grande

1 Teste de hipótese

$$H_0 : \mu = \mu_0 \text{ vs } H_1 : \mu \neq \mu_0.$$

Rejeita H_0 se $T^2 > \chi^2(\alpha)$ onde $\chi^2(\alpha)$ é o quantil α -superior da distribuição qui-quadrado com p graus de liberdade.

2 Intervalos T^2 simultâneos:

$$\mathbf{a}^\top \bar{\mathbf{X}} \mp \sqrt{\chi^2(\alpha)} \sqrt{\frac{\mathbf{a}^\top \mathbf{S}^{-1} \mathbf{a}}{n}}$$

3 Região de confiança μ

$$(\bar{\mathbf{X}} - \mu)^\top \mathbf{S}^{-1} (\bar{\mathbf{X}} - \mu) \leq \frac{\chi^2_{(p)}}{n}$$

Inferência para amostras grandes ao respeito do vetor de uma média: Exemplo

Suponha temos coletado uma amostra aleatória de 107 observações e $p = 5$ características e calculamos as seguintes estatísticas:

Variável	Média	Desvio Padrão
X_1	58,6	4,44
X_2	19,3	2,39
X_3	101,5	8,87
X_4	67,0	3,99
X_5	42,5	4,69

Construir os 5 intervalos simultâneos de 90% de confiança para as médias individuais μ_i , $i = 1, \dots, 5$

Temos amostras grandes ($n = 107 \gg p = 5$), usaremos a abordagem de amostras grandes para construir os intervalos simultâneos de 90%.

Inferência para amostras grandes ao respeito do vetor de uma média: Exemplo

$$\mu_1 = \bar{x}_1 \pm \sqrt{\chi_p^2(\alpha)} \sqrt{\frac{s_{11}}{n}} = 58,6 \pm \sqrt{9,236} \frac{4,44}{\sqrt{107}} = 58,6 \pm 6,034 \Rightarrow \mu_1 : (52,565; 64,635)$$

$$\mu_2 = \bar{x}_2 \pm \sqrt{\chi_p^2(\alpha)} \sqrt{\frac{s_{22}}{n}} = 19,3 \pm \sqrt{9,236} \frac{2,39}{\sqrt{107}} = 19,3 \pm 3,248 \Rightarrow \mu_2 : (16,052; 22,548)$$

$$\mu_3 = \bar{x}_3 \pm \sqrt{\chi_p^2(\alpha)} \sqrt{\frac{s_{33}}{n}} = 101,3 \pm \sqrt{9,236} \frac{8,87}{\sqrt{107}} = 101,3 \pm 12,056 \Rightarrow \mu_3 : (89,444; 113,556)$$

$$\mu_4 = \bar{x}_4 \pm \sqrt{\chi_p^2(\alpha)} \sqrt{\frac{s_{44}}{n}} = 67,0 \pm \sqrt{9,236} \frac{3,99}{\sqrt{107}} = 67,0 \pm 5,423 \Rightarrow \mu_4 : (61,577; 72,423)$$

$$\mu_5 = \bar{x}_5 \pm \sqrt{\chi_p^2(\alpha)} \sqrt{\frac{s_{55}}{n}} = 42,5 \pm \sqrt{9,236} \frac{4,69}{\sqrt{107}} = 42,5 \pm 6,374 \Rightarrow \mu_4 : (36,126; 48,874)$$

Inferência para amostras grandes ao respeito do vetor de uma média: Exemplo

Se usamos esses intervalos para testar a hipóteses nula

$$H_0 : \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \mu_4 \\ \mu_5 \end{pmatrix} = \begin{pmatrix} 55 \\ 25 \\ 111 \\ 59 \\ 34 \end{pmatrix}$$

Ao nível de confiança de 90%, poderia rejeitar a hipóteses nula?
(Por que?)